

Gemelo Digital Climático-Adaptativo para la Producción de Maíz Resiliente a la Sequía: Integración de Proyecciones CMIP6 y una Red Neuronal Físicamente Regularizada (CeresPINN)

Climate-Adaptive Digital Twin for Drought-Resilient Maize Production: Integration of CMIP6 Projections and a Physics-Regularized Neural Network (CeresPINN)

David Adrian Lucano Nieves¹, Geraldine Daniela Rojas Villegas¹

¹ Universidad Nacional de Trujillo, Escuela de Ingeniería de Sistemas, Trujillo, Perú

Autores de correspondencia: dalucanoni@unitru.edu.pe; gdrojasvi@unitru.edu.pe

RESUMEN

El planeta se calienta, incrementando el potencial de exposición del maíz a sequedades y temperaturas extremas, intensificando la demanda de herramientas entre las proyecciones climáticas del Proyecto de Intercomparación de Modelos Acoplados Fase 6 (CMIP6) y las opciones de gestión.: Sin embargo, los gemelos digitales agrícolas que integren dichas proyecciones con simulación agronómica interactiva aún son escasos. Este estudio provee el CeresPINN, un gemelo digital climático prototípico, a partir de datos de rendimientos del Servicio Nacional de Estadísticas Agrícolas de EE. UU. (USDA-NASS), de variables climáticas de NASA Earth Exchange Global Daily Downscaled Projections for CMIP6 (NEX-GDDP-CMIP6), de una red neuronal físicamente regularizada y un simulador diario de la fenología y del balance hídrico. La red neuronal tiene siete entradas y una pérdida que rige restricciones de monotonía sobre temperatura y precipitaciones. Se emplearon 22 160 registros de rendimiento, agregados en 36 medianas anuales independientes. El CeresPINN tuvo, durante los ocho años considerados para la prueba, una raíz del error cuadrático medio (RMSE) de 712.1 kg ha⁻¹, un error absoluto medio (MAE) de 604.2 kg ha⁻¹ y un coeficiente de determinación (R²) de 0.8251. La regularización en monotonía mostró una mejora sustancial frente a un MLP equivalente, aunque una regresión lineal simple y una regresión Ridge obtuvieron estimaciones puntuales ligeramente mejores sobre la misma partición. En el caso de Iowa–SSP5-8.5–2050, el riego deficitario fijado al 75 % implicaba una mejora en el rendimiento hasta el 7.29 %; la sensibilidad también arrojó una gran dependencia estructural del CO₂ con los parámetros del escenario.

Palabras clave: gemelo digital; maíz; CMIP6; NEX-GDDP; red neuronal físicamente regularizada; sequía; adaptación climática; balance hídrico.

INTRODUCCIÓN

El maíz es especialmente sensible a las interacciones de períodos de extrema temperatura y de sequía cuando se producen en la fase de floración y en la corte de grano; en los Estados Unidos, la coincidencia de sequía y temperaturas extremas ya disminuye el rendimiento por hectárea y la proporción del cultivo que llega a cosecharse, de esta manera considerar sólo el rendimiento potencial puede suponer una infravaloración del verdadero riesgo que guarda para la producción y la seguridad alimentaria (Xiao et al., 2025), y puede considerarse muy de actualidad con las recientes estimaciones mundiales: Jägermeyr et al. (2021) pronosticaron que a finales del siglo la productividad del maíz podría caer cerca de $\sim -6\%$ bajo el escenario de emisiones SSP1-2.6 y cerca de $\sim -24\%$ bajo el escenario de emisiones SSP5-8.5; Xu et al. (2024) pronosticaron una pérdida promedio del 21,4% en el maíz del noreste de China. A pesar de que estas cifras dependen en gran medida de la región, del modelo de proyección que se haya utilizado o de los supuestos que se hayan considerado en el análisis de la adaptación, muestran de forma general que la respuesta del cultivo no puede ser computada como una simple tendencia climática aislada.

Los modelos de cultivo mecanicistas basados en procesos - DSSAT/CERES-Maíz, APSIM, AquaCrop, WOFOST, SIMPLACE - siguen siendo el eje mecanicista básico de gran parte de la investigación agronómica. La literatura dedicada a la utilización de DSSAT para la predicción del maíz crece anualmente con un ritmo del 12,93 % por un interés específico sobre el cambio climático, la gestión de nitrógeno, el riego y la adaptación (Sakthivel et al., 2025). Debemos ser precisos y precisas, los modelos pueden trabajar con proyecciones climáticas futuras, incluso, es innecesario aclarar que los modelos pueden trabajar con CMIP6, por sus limitaciones prácticas, más que por las limitaciones propias del modelo de cultivo: calibración local del modelo de cultivo, parametrizaciones específicas del sitio, coste por la ejecución de ensayos amplios, propagación de incertidumbre. Por ejemplo, en el Corn Belt combinó variables sintéticas producidas por APSIM a modelos de machine learning y la reducción del error de la predicción (RMSE) se encontraba entre un 7 % y un 20 %, lo que evidenció que hay valor en la combinación de mecanismos físicos con datos (Shahhosseini et al., 2021). Esta línea de integración ha comenzado también en escenarios con poca disponibilidad de datos.

A escala más local, Cheng et al. (2022) integraron diferentes variables con algoritmos de machine learning para predecir el rendimiento del maíz a nivel de condado, en China. Este tipo de enfoque se pone de manifiesto en la necesidad de incorporar información multivariable y espacial para poder pasar de estimaciones agregadas a predicciones agrícolas de mayor resolución, ya que esta es aún una de las limitaciones de la implementación actual de CeresPINN.

Los gemelos digitales (DT) ya se han usado bastante en clima y meteorología, pero los DT pensados específicamente para la agricultura parecen escasear en la literatura (Escribà-Gelonch et al., 2024). Las revisiones sobre el tema describen arquitecturas por capas, con tres capas en el caso de Zhang et al. (2025c) y cinco en el de Melesse (2025). Ambos trabajos señalan que integrar datos de formatos y escalas distintas sigue siendo difíciles, y que la mala conectividad en zonas rurales complica la sincronización en tiempo real. CeresPINN puede leerse con esa misma lógica de capas: la red neuronal hace la inferencia y el simulador de balance hídrico aporta la parte física.

Las redes neuronales con implicaciones en física (PINN) se sitúan justo en la intersección de las dos líneas anteriores (modelos de cultivo y aprendizaje automático). En su versión estándar, las PINN incorporan explícitamente los principios físicos o las ecuaciones que describen el sistema (como se describe en la sección 3.3.2), por lo que se reduce de este modo el espacio de soluciones alternativas posibles (Raissi et al., 2019; Farea et al., 2024). En el caso de la agricultura, Shi et al. (2025) indicaron que los modelos híbridos que combinan modelos de procesos junto con deep learning resultan ser más sólidos que por separado, ya que tiene lugar un conflicto entre la caída del rendimiento del modelo y sus niveles de ruido en los datos o escasez, o bien, cuando se desea asegurar su habilidad de generalización a localizaciones que quedan fuera de los datos que conforman el conjunto de entrenamiento. En esta misma línea, el modelo AgriPINN restringió las trayectorias de biomasa a partir de procesos biofísicos, así como también recuperó las variables latentes de estrés hídrico y consiguió limitar el RMSE en un 43 % para algunas líneas bases (Shi et al., 2026). En la investigación se ha podido incluir como uno más la producción del cultivo = habilidad de la disponibilidad del agua a partir de modelaciones de arquitecturas de redes recurrentes del tipo RNN (Miranda et al., 2025); otros que han incorporado la asimilación de los datos y un machine learning con la combinación del modelado por reducción de un coste computacional regional de más del 99.8 % (Yu et al., 2025); otros que han añadido el modelo PINN con AquaCrop para estrategias de deficit irrigated (Zhang et al., 2025a).

A diferencia de la implementación vigente de CeresPINN, existen otras propuestas como PINN-SM que integran explícitamente las restricciones físicas para representar la dinámica de la humedad en la zona vadosa, resultando un contexto metodológico que contrasta con el que puede tener una PINN hidrológica en sentido estricto (Chavoshi et al., 2024). CeresPINN se entiende también dentro de esta misma transición, aunque tendrá que precisarse mejor su alcance real. A pesar de que el componente entrenado de CeresPINN no resuelve la ecuación de Richards dentro de su función de pérdida, emplea restricciones diferenciales de monotonía sobre la temperatura y sobre la precipitación. La dinámica hídrica en las tres

capas de suelo se computa después mediante un simulador determinista acoplado, no dentro de la red entrenada, lo que lleva a describir el sistema con mayor precisión como una red neuronal regularizada físicamente embarcada dentro de un gemelo digital híbrido, no como una PINN de Richards plenamente diferenciable.

El objetivo general de este trabajo fue desarrollar y auditar un prototipo capaz de vincular observaciones históricas de rendimiento, forzantes climáticos de CMIP6 y alternativas de manejo agrícola para explorar el riesgo climático futuro sobre el maíz. Los objetivos específicos fueron: (i) documentar la arquitectura del modelo y el linaje de los datos empleados; (ii) evaluar su desempeño predictivo mediante una validación retenida agrupada por año; (iii) examinar estrategias de fecha de siembra, duración varietal y riego; (iv) cuantificar la sensibilidad interna del modelo frente a sus variables de entrada; y (v) identificar las condiciones necesarias para avanzar hacia una validación espacial y externa.

A partir de los objetivos planteados, se formularon cinco preguntas de investigación: RQ1, ¿qué capacidad predictiva presenta CeresPINN sobre años no utilizados durante el entrenamiento y cómo se compara con líneas base evaluadas sobre la misma partición temporal?; RQ2, ¿cuál es la respuesta del prototipo en el caso demostrativo Iowa-SSP5-8.5-2050 bajo los parámetros internos de escenario utilizados?; RQ3, ¿cómo modifican la fecha de siembra, la duración del cultivar y el régimen de riego las salidas del gemelo digital?; RQ4, ¿qué variables dominan la sensibilidad global de la salida de rendimiento dentro de los rangos evaluados?; y RQ5, ¿Cómo varían los estados hídricos simulados entre los cuatro perfiles edáficos demostrativos y en qué medida estas diferencias se reflejan en la salida de rendimiento?

El protocolo original planteó además H0, según la cual no existiría diferencia significativa entre SSP2-4.5 y SSP5-8.5 hacia 2050, y H1, según la cual SSP5-8.5 produciría una pérdida de rendimiento de al menos 15 %, mitigable en al menos 50 % mediante adaptación. Estas hipótesis se mantienen como parte del protocolo original, pero no pudieron contrastarse adecuadamente en la implementación actual, debido a que SSP2-4.5 no formó parte del conjunto de entrenamiento y las intervenciones de manejo se implementaron mediante reglas deterministas.

La transición desde sistemas exclusivamente descriptivos hacia gemelos digitales capaces de apoyar decisiones agrícolas ya puede observarse en aplicaciones sobre cultivos. Xu et al. (2025) integraron un modelo de crecimiento de trigo con tecnología de gemelo digital para actualizar la simulación del cultivo y optimizar sus procesos de seguimiento y manejo mediante experimentos secuenciales. Este antecedente demuestra que el valor de un gemelo digital no se limita a reproducir virtualmente el estado de la planta, sino que depende de establecer un ciclo de retroalimentación que conecte observaciones, simulación y decisiones de manejo. No obstante, su aplicación se concentró en trigo y en la optimización durante el ciclo productivo, sin incorporar proyecciones climáticas CMIP6 de largo plazo como las consideradas en CeresPINN.

El presente trabajo sirve también al dilema específico, que desde el punto de vista de la Ingeniería de Software y de la Inteligencia Artificial debe dar cuenta del problema más general de cómo diseñar, auditar y validar sistemas híbridos de IA que combinan el aprendizaje de datos con el conocimiento del ámbito físico en un contexto de pocos datos. Hacer necesario el desarrollo de arquitecturas que sean trazables, evaluables y reproducibles. para ámbitos de tipo crítico, como el de la seguridad alimentaria bajo el cambio climático, se convierte en un problema abierto para la ingeniería de sistemas de IA de tipo confiable.

Las propuestas que este trabajo muestra en el campo de la ingeniería de sistemas de IA fiables son: (i) una arquitectura de framework híbrido que separa explícitamente una red neuronal físicamente regularizada de una determinada simulación determinista y biofísica, donde se exhibe cómo esta separación conlleva desacoplamientos que deben ser auditados sistemáticamente; (ii) una metodología para la auditoría controlada basada en la proporción entre ablaciones arquitectónicas, múltiples inicializaciones de pesos, bootstrap resampling y análisis de la sensibilidad global con el fin de poder dotar de una cuantificación de la robustez de los sistemas de IA en los campos de escasez de datos; (iii) una auditoría técnica y experimental a través de herramientas trazables que ayudan a la detección de limitaciones estructurales relevantes de los procesos de diseño, que nos lleva a encontrar redundancia de variables ya codificadas por escenario, dependencia temporal del predictor, desacoplamientos entre los estados del simulador biofísico y la salida neuronal de rendimiento; y (iv) una infraestructura total de reproducibilidad (contenedorización mediante Docker, integración continua mediante GitHub Actions y open source) que hace hincapié en buenas prácticas de la ingeniería del software para la investigación en IA aplicada.

3. MATERIALES Y MÉTODOS

3.1. Área de estudio y criterios de selección:

El ámbito conceptual abordado en el estudio es la producción de maíz en EEUU, centrándose en particular en la región del Corn Belt y en un caso ilustrativo en el condado de Story, Iowa. Ahora bien, cabe decir que la calibración efectivamente no fue espacial: los 22,160 registros obtenidos del USDA-NASS (de condados a estados) se agregaron mediante la mediana anual en el ámbito nacional. Por lo tanto, los criterios de la calibración, a saber: requerir un periodo de al menos 20 años por condado y excluir los condados que tuviesen más del 50% de área bajo riego, no llegaron a aplicarse sobre el modelo entrenado. El estudio del componente espacial que se llevó a cabo en cuatro campos de prueba (Iowa, El Bajío, las Pampas y el valle del Ebro) constituye exclusivamente una prueba de la respuesta del simulador ante suelos contrastantes, pero no la calibración del modelo a nivel local.

3.2. Fuentes y procesamiento de datos:

Rendimiento observado: Se emplearon los datos de rendimiento de maíz publicados por USDA-NASS Quick Stats entre 1990 y 2025. Después de convertir la columna de rendimiento a valores numéricos y descartar los registros incompletos, quedaron

22,160 observaciones utilizables. Para estabilizar el proceso de entrenamiento, se calculó la mediana de cada año, obteniendo así 36 valores objetivo independientes, expresados en bushels por acre, que luego se convirtieron a kilogramos por hectárea mediante el factor $1 \text{ bu/acre} = 62.77 \text{ kg/ha}$.

Forzantes climáticos: El conjunto de datos que se ha preparado con fines de entrenamiento incluía 98 filas climáticas regionales relacionadas con los tres escenarios SSP1-2.6, SSP3-7.0 y SSP5-8.5. El pipeline del sistema se encargaba de introducir los resúmenes que procedían de NEX-GDDP-CMIP6 y, si existían datos disponibles, interpolaba variables climáticas a lo largo de cada uno de los escenarios mencionados anteriormente. Sin embargo, dado que los archivos brutos que sirvieron de origen para las 98 filas que utilizó el checkpoint no se han preservado íntegramente en la versión auditada del repositorio, no se ha podido reconstruir la combinación exacta que forma parte de modelo-año-escenario. En el caso de que no existiera información climática, el sistema consideraba valores predefinidos del escenario. En concreto, valores de $+2.7^\circ\text{C}$, de -24% de precipitación y de 520 ppm de CO_2 para SSP5-8.5 hacen alusión a valores de la parametrización interna del prototipo y no deben interpretarse como extracción de un miembro concreto del ensamble NEX-GDDP-CMIP6. Para asegurar la reproducibilidad, las 98 filas climáticas procesadas que acabamos de describir son accesibles en el repositorio del proyecto en CSV, si bien no hemos mantenido íntegramente los archivos brutos de NEX-GDDP-CMIP6 que fueron origen de estas filas climáticas.

Suelo: El simulador opera con cuatro perfiles de capacidad de campo, punto de marchitez, saturación y conductividad hidráulica fijos y considerados únicamente para los campos de demostración. No se usaron bases de datos como SoilGrids o POLARIS, que sirven para construir bases de datos de perfil de suelo, así como tampoco datos de campo reales, para el entrenamiento del modelo. La evidencia disponible sugiere que la incorporación de los mapas actuales de propiedades del suelo junto a funciones de pedotransferencia podría mejorar significativamente la representación vertical e hidráulica de humedad del suelo (Xu et al., 2023), así que integrar estos productos se convierte en una prioridad para sustituir los perfiles incluidos en el modelo por perfiles derivados de dichas bases de datos, con trazabilidad espacial real.

3.3. Arquitectura y formulación de CeresPINN

3.3.1. Variables de entrada, estados y salidas

Las entradas directas a la red neuronal que ha sido entrenada incluyen:

- **Variables temporales y climáticas:** Año objetivo (year), la anomalía de temperatura (temp_anomaly_c), la anomalía realizada de forma porcentual de

precipitación (precip_anomaly_pct) y la concentración del dióxido de carbono (co2_ppm)

- **Variables sobre índices agroclimáticos derivados:** Riesgo de las olas de calor (heatwave_risk), precipitación estacional acumulada base (seasonal_precip_mm) y los días que hubo sequedad (secos) dados de manera consecutiva (seasonal_cdd)

Sumado a ellas, se contaron con entradas de manejo y edáficas para el simulador acoplado:

- **Genotipo y manejo:** Ciclo para el cultivar de maíz (short, medium, long cycle), la fertilización que se ha nitrogenado (nitrogen_application_kg_ha), la estrategia de irrigación que se ejecutará (rainfed, deficitarias o sensor inteligente) y la fecha en la que se dio la siembra.
- **Hidráulica de suelos:** Capacidad de campo (θ_{fc}), punto de la marchitez permanente (θ_{wp}), saturación evaluadas (θ_{sat}), conductividad hidráulica saturada (K_{sat}) y humedad en la fase inicial del perfil.

Con respecto a variables de estado:

- **Fenología y térmicas:** Grados día de desarrollo acumulado (GDD) y el estadio fenológico discretizado (desde VE hasta R6)
- **Dosel Vegetal:** índice de Área Foliar dinámico con senescencia (LAI), la altura de dicho dosel (m) y la profundidad radical efectiva (cm)
- **Balance hídrico estratificado mediante reservorios de suelo:** contenido volumétrico del agua (θ) en tres estratos (0–30 cm, 30–60 cm y 60–100 cm), infiltración neta, drenaje de manera profunda y balance diario de evapotranspiración mediante formulación simplificada basada en Priestley–Taylor.
- **Estrés agroclimático:** índice de estrés hídrico del cultivo (CWSI) y el factor de estrés térmico crítico ($T_{max} > 32^{\circ}\text{C}$).

La arquitectura posee dos cabezas de salida. La primera estima el rendimiento normalizado. La segunda genera una variable sigmoideal $h[0,1]$, originalmente concebida como un proxy de disponibilidad hídrica. Sin embargo, la cabeza número dos, no dispone de un objetivo observado de humedad, CWSI o almacenamiento de agua y no interviene en las restricciones de monotonicidad antes mencionadas. En el checkpoint auditado, su salida fue constante e igual a 0.5 sobre el conjunto de entrenamiento. Este es el motivo por el que no se interpreta en este trabajo como un estado hídrico aprendido o físicamente validado.

Las salidas del sistema deben distinguirse entre aquellas generadas directamente por la red neuronal y aquellas calculadas posteriormente por el simulador determinista. La red produce la estimación basal de rendimiento y una segunda salida sigmoideal no

supervisada. En cambio, la fenología, biomasa, evapotranspiración, CWSI, consumo de agua, rendimiento potencial, retorno económico y los índices de resiliencia se calculan luego mediante reglas y ecuaciones deterministas del simulador. Estas últimas variables no fueron objetivos supervisados durante todo el entrenamiento de la red.

3.3.2. Formulación física y balance de procesos

El aprendizaje de la red neuronal es mediado mediante restricciones de monotonicidad de manera ecofisiológica. Estas restricciones penalizan respuestas locales en las que el rendimiento que se ha predicho aumenta ante incrementos de la anomalía térmica o disminuye ante aumentos de precipitación estacional dentro del régimen de déficit considerado. De este modo, la información física incorporada durante el entrenamiento no corresponde a la solución explícita de una ecuación diferencial parcial, mas bien, es correspondiente a las restricciones diferenciales sobre la respuesta aprendida por dicha red.

De manera independiente, el gemelo incorpora un simulador determinista posterior encargado de hacer cálculos diariamente sobre la fenología, la evapotranspiración, el estrés hídrico y el almacenamiento de agua en tres estratos de suelo. Dicho componente utiliza parámetros como capacidad de campo, punto de marchitez, saturación y conductividad hidráulica. El módulo se encuentra inspirado en procesos hidrológicos de la zona radicular, pero la implementación actual no resuelve numéricamente la ecuación de Richards ni es diferenciable respecto de la red neuronal.

Como posible extensión del componente hídrico, los modelos de difusión fraccionaria permiten representar procesos de transporte con memoria y comportamientos no descritos adecuadamente por la difusión clásica. Granella (2026) mostró su utilidad para modelar transferencias complejas de la humedad en sistemas de agroalimentos. Aunque CeresPINN no implementa cálculo fraccionario, este enfoque podría evaluarse en versiones futuras para representar dinámicas hídricas realizadas de manera no local.

La separación entre la red neuronal y el simulador biofísico permite utilizar información agronómica dentro de un prototipo híbrido, aunque también constituye alguna limitación de la arquitectura actual. Los estados ejecutados de manera diaria y que fueron simulados no generan retroalimentación directamente a la salida de rendimiento aprendida por la red. Por ello, el conocimiento físico incorporado durante la etapa del entrenamiento debe de poder interpretarse específicamente como una regulación físicamente motivada a través de restricciones de monotonicidad, y no como la conservación de masa, solución de la ecuación de Richards (previamente mencionada) o cumplimiento de una ecuación de tipo: diferencial parcial.

3.3.3. Función de pérdida y entrenamiento

La red neuronal se entrenó minimizando una función compuesta por error supervisado, regularización de monotonidad y una penalización L2 explícita:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \mathcal{L}_{\text{phys}} + 10^{-4} \sum_j \theta_j^2$$

donde la pérdida supervisada corresponde al error cuadrático medio entre el rendimiento normalizado observado y el estimado:

$$\mathcal{L}_{\text{data}} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

La configuración completa del entrenamiento realizado es sintetizada en la **Tabla 1**.

Parámetro	Configuración
Entradas	7
Capas Ocultas	4 x 128
Activación	Tanh
Dropout	0.05
Cabeza rendimiento	128 → 64 ReLU → 1
Segunda cabeza	128 → 32 ReLU → 1 Sigmoid
Parámetros entrenables	63 042
Optimizador	Adam
Learning rate	0.001
Scheduler	No
Adam weight decay	10^{-5}
Penalización L2 manual	$10^{-4} \sum \theta^2$
Batch size	64
Épocas	300
Seed principal	42

Normalización X	z-score sobre train
Normalización y	min-max sobre train
Early stopping	No
Checkpoint	Estado de la época final

Tabla 1. Especificación de la arquitectura, los hiperparámetros y la configuración de entrenamiento de CeresPINN

La arquitectura fue deliberadamente compacta para limitar la gran complejidad del modelo frente al reducido número de años independientes que se encuentran disponibles. Se empleó Tanh por su respuesta que resulta suave y diferenciable, adecuada para calcular derivadas locales utilizadas en la regularización de monotonicidad. El dropout de 0.05 se utilizó como una regularización ligera, evitando tasas más altas que pudieran degradar el aprendizaje en un conjunto de entrenamiento pequeño. No se realizó una búsqueda exhaustiva de hiperparámetros; por ello, estas elecciones deben interpretarse como la configuración de un prototipo y no como una arquitectura óptima.

La regularización físicamente motivada es calculada a partir de lo que son las derivadas del rendimiento normalizado con respecto a las entradas normalizadas de anomalía térmica y precipitación de las estaciones:

$$\mathcal{L}_{\text{mono}} = 0.5 \text{ E } [\text{ReLU}(\frac{\partial Y}{\partial T})] + 0.5 \text{ E } [\text{ReLU}(-\frac{\partial Y}{\partial P})]$$

El código desarrollado contiene además una penalización de rango, la cual está asociada con la segunda cabeza sigmoidal:

$$\mathcal{L}_{\text{range}} = 0.5 \{ \text{E}[\text{ReLU}(h-1)] + \text{E}[\text{ReLU}(-h)] \},$$

pero, dado que h se obtiene mediante una función Sigmoid y por construcción $0 \leq h \leq 1$, este término fue nulo en el checkpoint auditado y no constituye una restricción física efectiva. Durante toda la optimización se utilizó adicionalmente “Adam” con $\text{weight_decay} = 10^{-5}$, independiente de la penalización L2 manual con valor de 10^{-4} .

La arquitectura implementada corresponde a la implementación de un perceptrón multicapa con cuatro capas ocultas de 128 unidades y dos cabezas de salida. El entrenamiento se realizó en el entorno de PyTorch mediante Adam y los parámetros aprendidos y estadísticas de normalización se almacenaron en dos archivos nombrados como: `cerespinn_pinn.pt` y `cerespinn_metadata.json`.

3.3.4. Módulo de simulación de escenarios de manejo

La capa de inferencia (PinnInference) permite ejecutar simulaciones del tipo what-if mediante ciertas modificaciones discretas de variables de manejo, entre ellas la fecha de sembradío, la duración del cultivar, el régimen de riego y la fertilización nitrogenada. La forma actual de implementación no resuelve un problema de optimización ni aprende políticas de manejo a partir de las observaciones experimentales. Las configuraciones fueron evaluadas mediante multiplicadores del tipo determinista, e incorporados en el software, permitiendo comparar el cambio de las salidas frente a un escenario base. En consecuencia, los resultados obtenidos deben interpretarse como comparaciones de tipo exploratorias entre escenarios y no como soluciones óptimas para el tema agronómico. La simulación what if resulta consistente con el rol que la literatura atribuye a los gemelos digitales como herramientas de exploración de escenarios de adaptación climática (Purcell et al., 2023).

3.4. Calibración y validación del modelo

3.4.1. Validación histórica (*hindcast*)

El conjunto de datos es abundante y tiene como años abarcados, los pertenecientes al periodo 1990–2025. La separación entre entrenamiento y prueba se realizó a nivel de año, mediante un grouped-random-year-holdout con semilla número 42. Veintiocho años fueron asignados al entrenamiento y ocho a la prueba, manteniendo juntas las tres réplicas SSP correspondientes a cada año para evitar que un mismo objetivo anual apareciera simultáneamente en ambos subconjuntos de datos. Los años de prueba fueron 1991, 1992, 1998, 2001, 2003, 2004, 2011 y 2024. Es por esta razón que la unidad independiente empleada para la inferencia estadística fue el año ($n=8$) y no cada fila año–escenario ($n=24$). Esta forma de partir la información representa una validación retenida agrupada por año, pero no una validación temporal estrictamente del tipo prospectiva.

3.4.2. Contraste de plausibilidad con evidencia externa

Como contraste de plausibilidad, la respuesta generada por CeresPINN fue comparada de forma cualitativa con resultados publicados en estudios agronómicos independientes. Este procedimiento efectuado permite contextualizar la dirección y magnitud de ciertas respuestas del prototipo, pero no constituye una validación externa formal, debido a que no se aplicó el modelo sobre un conjunto independiente de observaciones de campo no utilizado durante su desarrollo.

3.5. Proyecciones climáticas, ensamble y escenarios

3.5.1. Datos NEX-GDDP-CMIP6

La sexta fase del Proyecto de Intercomparación de Modelos Acoplados, CMIP6, estableció una estructura experimental común para estudiar la respuesta del sistema terrestre frente a distintos forzamientos, examinar el origen de los sesgos sistemáticos de los modelos y evaluar el cambio climático futuro considerando la variabilidad natural y la incertidumbre asociada con los escenarios. Esta organización facilita la comparación entre modelos climáticos y constituye la base científica de los experimentos históricos y futuros posteriormente empleados en productos climáticos derivados como NEX-GDDP-CMIP6 (Eyring et al., 2016)

El producto NEX-GDDP-CMIP6 de la NASA ofrece proyecciones diarias, tanto históricas como futuras, que cubren el periodo 1950-2100, derivadas de 35 modelos climáticos, cinco experimentos y ocho variables, con una resolución espacial de 0.25° obtenida mediante un método diario de corrección de sesgo y desagregación espacial (Thrasher et al., 2022). Esta resolución resulta adecuada para estudios de alcance regional, aunque no equivale al clima observado a escala de parcela individual. La reducción de escalas debe aportar valor, pero conserva errores del modelo climático original y presenta problemas para la representación de las precipitaciones convectivas subdiarias y los eventos extremos, especialmente cuando las relaciones estadísticas que se emplean dejan de ser estacionarias (Maraun et al., 2010).

Existen corregidores de sesgo ya documentados en la literatura: en Senegal, el CDF-t fue capaz de reducir el sesgo medio de la precipitación anual de -223.37 a -49.17 mm y el sesgo térmico de +0.8 a +0.22 °C, mientras que preservaba las tendencias de largo plazo (Mbengue et al., 2026). Por su parte, el QDM corregía las distribuciones históricas conservando los cambios específicos por cuantil, lo que ayudaba a no perder la señal de calentamiento en la cola superior de la distribución (de Souza et al., 2026). Además, Galmarini et al. (2024) encontraron que los métodos de corrección multivariados eran preferibles cuando el modelo de cultivo se ajusta de forma conjunta entre la temperatura, la precipitación y la radiación, y es necesario aclarar que CeresPINN tampoco aplicó ninguno de estos métodos (CDF-t, QDM o MBCn), sino que se limitó a trabajar con los datos regionales de NEX ya procesados y con valores de referencia predefinidos cuando no había valores.

Como fuentes potenciales de observación histórica, CHIRPS y CHIRTS también han sido evaluadas en la literatura. Alsilibe et al. (2023) reportaron un buen desempeño estacional de CHIRPS en una cuenca árida, con una correlación de 0.79 durante la estación húmeda, aunque con menor habilidad para capturar lluvias diarias ligeras. Uscamayta-Ferrano et al. (2025), por su parte, refinaron la resolución de CHIRTS de 5 a 1 km mediante aprendizaje automático y restricciones físicas, logrando que Random Forest redujera el error de temperatura mínima en 47.1 %, aunque con mejoras temporales modestas y dependientes de qué tan representativa fuera la zona analizada. Ninguna de estas dos fuentes formó parte del conjunto de entrenamiento efectivamente utilizado en CeresPINN; se consideran, más bien, insumos recomendados para una siguiente versión del sistema.

3.5.2. Selección del ensamble GCM

Los siete modelos de circulación general que fueron considerados como candidatos para un análisis de ensamble fueron: CESM2, EC-Earth3, MIROC6, MPI-ESM1-2-LR, MRI-ESM2-0, ACCESS-ESM1-5 y CanESM5. Sin embargo, el experimento factorial completo sobre los siete miembros no fue ejecutado en la versión del prototipo evaluado. Por lo tanto, estos modelos pueden considerarse como los que han sido previstos para una extensión del análisis y no como un ensamble cuyos resultados se reportan en este estudio.

3.5.3. Escenarios SSP

Los cuatro escenarios prioritarios de la Trayectoria Socioeconómica Compartida definidos por ScenarioMIP —SSP1-2.6, SSP2-4.5, SSP3-7.0 y SSP5-8.5—, que incluyen las trayectorias de forzamiento radiativo e incertidumbre socioeconómica más abundantes, fueron tomados en consideración; en el caso específico de la SSP3-7.0, corresponde a una trayectoria no mitigada que servía para cubrir un vacío detectado en la generación anterior de escenarios, CMIP5 (O'Neill et al., 2016). Sin embargo, como se desarrolla en la sección 3.5, el entrenamiento del modelo que aquí se implementa solo se llevó a cabo con tres de estos cuatro escenarios.

3.5.4. Transformación de CMIP6 a entradas del PINN

El pipeline combina parámetros predefinidos por escenario con información climática resumida cuando esta se encuentra disponible. Para los escenarios SSP1-2.6, SSP3-7.0 y SSP5-8.5 se utilizan plantillas que incluyen anomalías climáticas, concentración de CO₂ y un indicador de riesgo térmico. Los datos derivados de NEX-GDDP-CMIP6 pueden sustituir o interpolar determinadas variables, principalmente temperatura y precipitación estacional. Sin embargo, no todas las entradas proceden directamente de NEX. En particular, *heatwave_risk*, CO₂ y algunos parámetros de escenario se generan mediante reglas internas. Además, los archivos brutos utilizados para construir las 98 filas climáticas asociadas al checkpoint no se preservaron

íntegramente, por lo que su procedencia exacta no puede reconstruirse para cada combinación año-escenario.

3.6. Estrategias de adaptación

Se evaluaron tres intervenciones de manejo, además de su combinación: adelantar la fecha de siembra en 14 días, cambiar hacia un cultivar de ciclo más corto, y aplicar riego deficitario al 75 %. La elección de estas estrategias se sustenta en la literatura disponible: la fecha de siembra, la duración del ciclo, el riego y la fertilización concentran la mayor parte de las opciones de adaptación estudiadas hasta ahora (Wakatsuki et al., 2023); ajustar oportunamente el periodo de crecimiento puede contribuir a recuperar parte del rendimiento perdido (Minoli et al., 2022); y el riego resulta particularmente efectivo bajo condiciones de déficit hídrico, aunque con beneficios marginales decrecientes a medida que aumenta el volumen aplicado (Abramoff et al., 2023; Zhang et al., 2025b).

3.7. Análisis estadístico, sensibilidad y robustez

La evaluación estadística fue realizada considerando como unidad independiente los ocho años reservados para la prueba. Se calcularon el RMSE, MAE y R^2 sobre las predicciones agregadas por año. Asimismo, se aplicó una prueba t-pareada entre los rendimientos predichos y observados, se calculó el sesgo medio y el tamaño del efecto pareado d_z , así como también se realizó la prueba de Kolmogorov-Smirnov como contraste descriptivo entre distribuciones.

La incertidumbre de las métricas fue estimada mediante un promedio de 20 000 remuestreos bootstrap sobre los ocho años independientes, obteniéndose intervalos de confianza del 95 % para RMSE, MAE y R^2 .

El análisis de sensibilidad global mediante índices de Sobol se realizó a las variables con variación efectiva auditada en el checkpoint: anomalía térmica, precipitación y la concentración del CO_2 . No se estimó un índice Sobol interpretable para `seasonal_cdd` debido a que este permaneció constante en el conjunto de entrenamiento que ha sido considerado.

Para evaluar la sensibilidad a la inicialización, CeresPINN y el MLP equivalente sin regularización de monotonidad tuvieron un entrenamiento adicional con diez semillas: 0–8 y 42. Las estadísticas agregadas de estas ejecuciones se utilizaron para poder distinguir el comportamiento de una corrida única de la estabilidad de la arquitectura implementada.

Finalmente, se realizaron pruebas de robustez incrustando dentro de las entradas un ruido de tipo gaussiano con desviación estándar equivalente al 5 % de la desviación observada durante la etapa del entrenamiento y mediante una prueba específica de dependencia temporal en la que la variable “año” ha sido sustituida por su respectiva media de entrenamiento.

El análisis de sensibilidad global se implementó mediante secuencias Sobol utilizando $N=32,768$ muestras base, correspondientes a 163 840 evaluaciones del modelo. Los índices de primer orden y totales se estimaron mediante el procedimiento de Jansen y sus intervalos de confianza mediante 500 remuestreos bootstrap, utilizando semilla 42.

Las pruebas estadísticas realizadas responden a objetivos analíticos diferentes —sesgo pareado, contraste descriptivo de distribuciones e incertidumbre de métricas— y no constituyen una familia de contrastes múltiples sobre una misma hipótesis. Por ello, no se aplicó una corrección global por multiplicidad, ya que cada prueba evalúa una pregunta independiente y no representa una búsqueda exhaustiva de significancia sobre una misma hipótesis nula. Dado que la unidad independiente de evaluación es el año ($n=8$), las pruebas estadísticas presentan una potencia reducida para detectar diferencias entre los modelos. Por esta razón, los valores p se interpretaron de forma descriptiva y conjuntamente con tamaños del efecto e intervalos bootstrap; la ausencia de significancia estadística no debe entenderse como evidencia de equivalencia entre modelos, sino como un reflejo de la poca información empírica disponible en el conjunto de prueba.

RESULTADOS

4.1. Caracterización climática:

La información del conjunto de datos final se conformó mediante la combinación de los registros de USDA-NASS con datos climáticos de NEX-GDDP, siendo 22,160 observaciones de rendimiento que finalizan con 36 valores objetivo anuales, con 98 filas climáticas de tipo regional. Con la expansión de estas observaciones por escenarios, se obtuvo un total de 108 ejemplos del conjunto de entrenamiento, notando que los datos y el tamaño del conjunto objetivo seguían siendo 36 observaciones independientes. Esta última es una distinción importante, ya que repetir los datos por escenario condiciona el entrenamiento del modelo, pero no equivale al uso de observaciones adicionales que sí sean independientes. En definitiva, el conjunto de datos se compuso de 22,160 observaciones originales de USDA-NASS correspondientes al periodo 1990-2025 que derivaron en 36 medianas anuales independientes, a las que se añadieron 98 filas climáticas del escenario SSP construidas mediante los datos climáticos disponibles y los parámetros internos del modelo. El linaje del conjunto de datos puede resumirse en la Figura 1.

Figura 1. Linaje y partición de los datos utilizados por CeresPINN



Figura 1. Trazabilidad y segmentación de los datos empleados en CeresPINN

4.2. Desempeño hindcast

Sobre las 24 filas año–escenario reservadas para prueba, CeresPINN obtuvo un RMSE de 717.4 kg ha^{-1} , un MAE de 618.3 kg ha^{-1} y un R^2 de 0.8225. Sin embargo, estas 24 filas proceden de ocho años independientes replicados entre tres escenarios; por tanto, el año se consideró como unidad experimental principal. Tras promediar las tres predicciones correspondientes a cada año, el RMSE fue de 712.1 kg ha^{-1} , el MAE de 604.2 kg ha^{-1} y el R^2 de 0.8251.

Sobre los ocho años independientes, la prueba t pareada produjo $t(7) = 0.1734$ y $p = 0.8672$, con un sesgo medio de $+46.6 \text{ kg ha}^{-1}$ y un tamaño del efecto $dz = 0.0613$. La prueba de Kolmogorov-Smirnov produjo $D = 0.25$ y $p = 0.9801$. Estos valores no deben interpretarse como evidencia de equivalencia debido al pequeño tamaño de muestra. La correspondencia entre valores observados y predichos se muestra en la Figura 2.

Figura 2. Observado vs. predicho en los 8 años independientes de prueba




Figura 2. Observado vs. predicho en los 8 años independientes de prueba

El remuestreo bootstrap con 20 000 iteraciones produjo un IC del 95 % de $[465.9, 915.5] \text{ kg ha}^{-1}$ para RMSE, $[343.8, 862.5] \text{ kg ha}^{-1}$ para MAE y $[-0.1071, 0.9355]$ para R^2 . La amplitud del intervalo de R^2 evidencia una incertidumbre considerable asociada con los ocho años disponibles para evaluación.

Como comparación sobre la misma partición temporal, CeresPINN obtuvo $RMSE = 712.13 \text{ kg ha}^{-1}$, $MAE = 604.19 \text{ kg ha}^{-1}$ y $R^2 = 0.8251$. La regresión lineal alcanzó $642.19 \text{ kg ha}^{-1}$, $557.23 \text{ kg ha}^{-1}$ y $R^2 = 0.8578$; Ridge obtuvo $644.85 \text{ kg ha}^{-1}$, $549.83 \text{ kg ha}^{-1}$ y $R^2 = 0.8566$; Random Forest obtuvo $1\,210.04 \text{ kg ha}^{-1}$, $890.24 \text{ kg ha}^{-1}$ y $R^2 = 0.4950$; y el MLP con arquitectura equivalente pero sin regularización de monotonicidad alcanzó $RMSE = 1\,180.99 \text{ kg ha}^{-1}$, $MAE = 979.30 \text{ kg ha}^{-1}$ y $R^2 = 0.5189$. Por tanto, CeresPINN mejoró de manera sustancial respecto del MLP equivalente, aunque las estimaciones puntuales de regresión lineal y Ridge fueron mejores.

El bootstrap de las diferencias de error por año mostró que los intervalos del 95 % para CeresPINN frente a regresión lineal y Ridge incluyeron cero, por lo que no se observó evidencia estadística suficiente de una diferencia entre estos modelos en los ocho años disponibles. En contraste, la diferencia frente al MLP sin monotonicidad presentó intervalos de confianza que no incluyeron cero tanto para RMSE como para MAE, respaldando el efecto de la regularización dentro de la misma arquitectura neuronal.

En las diez semillas evaluadas, CeresPINN obtuvo un RMSE medio de $776.79 \pm 42.55 \text{ kg ha}^{-1}$ y un R^2 medio de 0.7913 ± 0.0227 . El MLP sin regularización alcanzó un RMSE medio de $1\,049.59 \pm 137.87 \text{ kg ha}^{-1}$ y un R^2 medio de 0.6141 ± 0.1049 . Estos resultados indican que la mejora frente al MLP equivalente no depende exclusivamente de la semilla 42, aunque la inferencia continúa limitada por los ocho años independientes de prueba. La estabilidad frente a distintas inicializaciones se presenta en la Figura 3.




Figura 3. Variabilidad multi-seed del RMSE

En respuesta a RQ1, CeresPINN mostró capacidad predictiva sobre los ocho años independientes reservados para prueba, con $\text{RMSE} = 712.1 \text{ kg ha}^{-1}$ y $R^2 = 0.8251$ en la corrida principal. La regularización de monotonidad incrementó consistentemente el rendimiento respecto del MLP correspondiente. La regresión lineal y Ridge obtuvieron mejores estimaciones puntuales, aunque sus diferencias respecto de CeresPINN no resultaron significativas bajo bootstrap.

4.3. Proyecciones bajo CMIP6

Se simula un caso de salida para una parcela que se localiza en el norte de Ames, Iowa, proyectada al año 2050, según el escenario SSP5-8.5, del que se predicen el aumento de $+2.7 \text{ }^{\circ}\text{C}$, la reducción de 24 % de la precipitación, la concentración de CO_2 de 520 ppm, la siembra el día 15 de mayo, el ciclo medio, la aplicación deficitario del 50 %, la humedad de suelo inicial del 60 % y la aplicación de 180 kg de nitrógeno por hectárea. En este sentido, el sistema devolvió una salida de rendimiento de $13\,331 \text{ kg ha}^{-1}$, un valor que se encuentra en torno a un 1.3 % por debajo del rendimiento potencial interno del cultivar que fue parametrizado; pero este porcentaje no hay que considerarlo como una pérdida atribuible al cambio climático, porque el rendimiento potencial que simuló el cultivo es un valor heurístico constante y no un contrafactual que se pueda observar en el mundo real.

Conviene remarcar que esta cifra no constituye una proyección regional derivada de un ensamble climático completo de CMIP6, sino el resultado de una simulación puntual condicionada por los valores de referencia y los multiplicadores internos del prototipo; el experimento factorial que incorporaría múltiples miembros del ensamble GCM todavía no se ha ejecutado, por lo que tampoco se dispone de una curva comparativa entre los distintos escenarios SSP. Las pérdidas de entre 6 % y 24 % reportadas en evaluaciones regionales o globales de la literatura (Xiao et al., 2025; Jägermeyr et al., 2021; Xu et al., 2024) se emplean aquí únicamente como marco de referencia contextual, y no como un sustituto de los resultados propios de este estudio.

En respuesta a RQ2, el caso demostrativo Iowa–SSP5-8.5–2050 produjo una salida de rendimiento de $13\,331 \text{ kg ha}^{-1}$ bajo los parámetros internos evaluados. Este resultado caracteriza la respuesta del prototipo para dicha configuración puntual y no constituye una proyección regional basada en un ensamble completo de modelos climáticos.

4.4. Respuesta a escenarios de manejo

En el caso demostrativo Iowa–SSP5-8.5–2050, el escenario base tuvo como resultado la producción de $13\,331 \text{ kg ha}^{-1}$. Adelantar la siembra 14 días logró mantener la salida de rendimiento en $13\,331 \text{ kg ha}^{-1}$ y aumentó el estrés hídrico diario. El cultivar de

ciclo corto redujo el rendimiento a 11 731 kg ha⁻¹, aunque disminuyó la duración del ciclo y el consumo hídrico. El riego deficitario al 75 % elevó el rendimiento a 14 303 kg ha⁻¹, equivalente a un incremento de 7.29 % frente al escenario basal. La combinación de intervenciones produjo 12 587 kg ha⁻¹. Las diferencias de rendimiento asociadas con cultivar, régimen de riego, nitrógeno y CO₂ son introducidas mediante multiplicadores deterministas aplicados después de obtener la salida basal del checkpoint. En particular, el incremento asociado al riego al 75 % se debe al cambio del multiplicador de riego de 0.96 a 1.03, mientras que el cultivar corto aplica un factor de 0.88. La fecha de siembra no forma parte de las siete entradas de la red de rendimiento, por lo que es posible que su modificación pueda llegar a alterar la fenología y el estrés diario sin modificar directamente la salida base. En consecuencia, estos experimentos representan análisis what-if del prototipo y no efectos de manejo aprendidos a partir de las observaciones experimentales.

En respuesta a RQ3, los escenarios de manejo modificaron las salidas del prototipo de manera diferenciada: el riego a un nivel del 75 % produjo el mayor rendimiento entre las configuraciones evaluadas, el cultivar de ciclo corto pudo reducir el rendimiento y el adelanto de siembra no modificó directamente la salida neuronal. Estas diferencias tienen que interpretarse como respuestas del sistema a reglas deterministas de manejo y no como los efectos aprendidos u optimizados a partir de datos de índole experimental.

4.5. Sensibilidad

Sobol produjo índices de primer orden S1 de 0.01609 para anomalía térmica, 0.00443 para precipitación y 0.97708 para CO₂. Los índices totales ST fueron 0.01640, 0.00678 y 0.97922, respectivamente. Los intervalos bootstrap del 95 % fueron [0.00573, 0.02649], [-0.00606, 0.01545] y [0.97670, 0.97743] para S1, respectivamente. La aparente dominancia del CO₂ no debe interpretarse de manera causal. Dentro del conjunto de entrenamiento, CO₂ presenta una correlación de aproximadamente 0.999 con `heatwave_risk` y de 0.951 con la codificación del forzamiento del escenario, por lo que estas entradas contienen información considerada redundante. En contraste, la correlación entre año y CO₂ durante el periodo de entrenamiento es aproximadamente nula. `seasonal_cdd` permaneció constante y, por ello, no se estimó un índice interpretable para esta variable.

La prueba de robustez frente a ruido gaussiano equivalente al 5 % de la desviación estándar de entrenamiento incrementó el RMSE de las 24 filas en solo 0.51 % durante un total de 1 000 repeticiones. En contraste, sustituir la variable año por su media de entrenamiento elevó el RMSE 188.2 %, mostrando una dependencia temporal considerable del modelo. Este comportamiento demuestra que se limita la interpretación causal de las sensibilidades y la extrapolación hacia horizontes climáticos futuros.

En respuesta a RQ4, el análisis global de sensibilidad identificó al CO₂ como la entrada dominante dentro de todos los rangos puestos a evaluación. Sin embargo, la fuerte redundancia con *heatwave_risk* y con la codificación del escenario impide interpretar esta dominancia como un efecto fisiológico causal; adicionalmente, la prueba de sustitución del año evidenció la dependencia del tiempo considerable del predictor.

4.6. Respuesta del simulador ante perfiles edáficos contrastantes

El orden de estrés hídrico según el CWSI máximo fue El Bajío, luego Ebro, siguiendo Pampas y finalizando con Iowa. Sin embargo, los cuatro campos produjeron una salida de rendimiento idéntica de 13 331 kg ha⁻¹. Esta igualdad se explica porque la localización y los parámetros edáficos modifican las trayectorias del simulador diario, pero no forman parte de la cabeza neuronal que determina el rendimiento base. Por ello, el análisis demuestra diferencias en la respuesta hídrica del simulador, pero esto no llega a considerarse como evidencia de vulnerabilidad espacial aprendida o validada.

En respuesta a RQ5, los perfiles edáficos modificaron las trayectorias de estrés hídrico del sistema simulador, pero no la salida base de rendimiento, que permaneció idéntica entre los cuatro campos demostrativos. Concluyendo en que la implementación actual representa diferencias biofísicas en el simulador diario, pero aún no ha logrado incorporar una respuesta espacial del rendimiento aprendida por la red.

DISCUSIÓN

5.1. Evaluación de las hipótesis originales

No fue posible contrastar la hipótesis H0, porque el escenario SSP2-4.5 no está incluido entre los que se han examinado en el modelo considerado. La hipótesis H1 tampoco fue confirmada: el ensamble completo de modelos de circulación general no llegó a ejecutarse. Ninguna de las combinaciones de manejo que se han evaluado consiguió reducir pérdidas climáticas del 15 % o superiores, como inicialmente se había propuesto. Así, si bien el riego deficitario al 75 % sí que obtuvo un incremento del 7.29 % frente al manejo basal, en este caso el resultado obtenido se debe en parte a un multiplicador ya predefinido en el sistema y no a un ajuste calibrado con datos experimentales.

Para finalizar, esta conclusión negativa es más interesante metodológicamente que una confirmación basada en supuestos no verificados o en pruebas de sustitución poco robustas. Aunque la literatura externa muestra que las pérdidas que podrían ser proyectadas podrían ser importantes y que algunas estrategias de adaptación funcionan (Jägermeyr et al., 2021; Xu et al., 2024; Abramoff et al., 2023), esta no podía sustituir la que debería generar el propio sistema estudiado.

5.2. Contraste con la literatura sobre impactos climáticos

Respecto a la partición de prueba retenida durante los ocho años, el modelo CeresPINN alcanzó $R^2 = 0.8251$ y $RMSE = 712.13 \text{ kg ha}^{-1}$. Las estimaciones puntuales de la regresión lineal simple y de Ridge fueron mejores, obteniendo $R^2 = 0.8578$ y $R^2 = 0.8566$; no obstante, los intervalos de bootstrap al 95 % de las diferencias de RMSE y MAE de estos modelos frente al de CeresPINN incluyeron cero. Por lo referido, con el tamaño muestral disponible no existe suficiente evidencia como para establecer alguna diferencia entre CeresPINN y los modelos de regresión lineal simple y Ridge. En combinación, el MLP con la misma arquitectura, pero desprovisto de regularización de monotonicidad, alcanzó $RMSE = 1\,180.99 \text{ kg ha}^{-1}$ y $R^2 = 0.5189$ y el intervalo bootstrap de su diferencia contra el de CeresPINN no incluyó cero. La evaluación sobre diez semillas también mostró una menor variabilidad y mejor desempeño medio del modelo CeresPINN frente al MLP equivalente. En resumen, estos resultados apoyan el efecto estabilizador de la regularización de monotonicidad en la arquitectura neuronal que fue evaluada, pero no demuestran una superioridad predictiva frente a modelos lineales más simples.

Otra alternativa para incrementar la calibración espacial de los modelos de cultivo radica en incluir observaciones de la Tierra obtenidas a partir de la percepción remota. Dokoohaki et al. (2022) mostraron el uso de información obtenida del Sentinel-2 y Landsat-8 para restringir los parámetros de APSIM-Maize usando emulación y optimización bayesiana. Este método es interesante para CeresPINN porque podría sustituir parte de su actual parametrización global por información espacial, sobre el estado del dosel y la variabilidad del cultivo, así como reducir la desconexión entre los perfiles locales del suelo y la salida final en términos de rendimiento.

La incorporación de variables observables del cultivo también podría servir de complemento a las entradas climáticas. Pukrongta et al. (2023) evaluaron un modelo de machine learning para predecir el rendimiento de grano de maíz a partir del contenido de clorofila e índices de vegetación. Estas variables incorporan información sobre el estado fisiológico real de la planta y podrían ser utilizadas en futuras versiones de CeresPINN como observaciones intermedias para actualizar el gemelo digital a lo largo de la temporada. Su inclusión podría servir para contrastar si el estrés inferido por el simulador hídrico afecta al dosel antes de predecir el rendimiento final.

Otra dimensión que podría incorporarse explícitamente es la variabilidad varietal. Han et al. (2024) evaluaron algoritmos de aprendizaje automático para predecir el rendimiento de diferentes cultivares de maíz con fines de promoción y siembra de precisión. En CeresPINN, el tipo de cultivar interviene actualmente mediante reglas deterministas posteriores a la salida neuronal; una extensión futura podría incorporar características varietales observadas directamente dentro del modelo predictivo y evaluar si estas mejoran su capacidad de generalización.

Alimagham et al. (2025) también trabajaron con pocos datos. Combinaron un modelo de cultivo basado en procesos con Random Forest, alimentado con variables ecofisiológicas, para proyectar el rendimiento del maíz bajo escenarios CMIP6. Ese esquema logra continuidad geográfica, pero el Random Forest no impone ninguna ecuación como restricción. En CeresPINN, en cambio, la monotonicidad sí entra en la función de pérdida, aunque eso no lo convierte en una PINN completa, como se aclaró en la Introducción.

La relevancia agronómica de la evapotranspiración y la humedad del suelo respalda esta línea de trabajo futuro. Hlavinka et al. (2017) identificaron la evapotranspiración real acumulada como el indicador de sequía más explicativo del rendimiento, mientras que Yu et al. (2025) encontraron que la radiación, la humedad y la lluvia durante la etapa de elongación resultaron determinantes para la estimación regional del rendimiento. En contraste, la sensibilidad casi exclusiva de CeresPINN frente al CO_2 contradice este patrón observado en la literatura, y debe interpretarse como un indicio de confusión estadística dentro del modelo, más que como un hallazgo agronómico genuino.

5.3. Respuesta del prototipo al adelanto de la fecha de siembra

Desde el punto de vista de la agronomía, el adelantar la siembra puede desplazar la etapa de floración hacia periodos con menor exposición a temperaturas extremas, mecanismo documentado en estudios de adaptación climática (Niu et al., 2026). Sin embargo, CeresPINN no reprodujo este beneficio en el caso demostrativo: adelantar la siembra 14 días mantuvo invariable la salida de rendimiento y aumentó el estrés hídrico calculado mediante el simulador. La discrepancia presente resulta ser coherente con una limitación estructural de la implementación actual, ya que la fecha de siembra modifica las trayectorias fenológicas e hídricas diarias, pero estas variables no logran retroalimentar directamente la cabeza neuronal de rendimiento. Por ello, el resultado no contradice necesariamente el mecanismo descrito en la literatura; evidencia que dicho mecanismo todavía no se encuentra acoplado de extremo a extremo dentro del prototipo.

5.4. Desempeño computacional de la implementación

En el entorno auditado con Windows 11, Intel Core i5-12450H, PyTorch 2.6.0+cpu y ocho hilos de ejecución, el entrenamiento de 300 épocas sobre las 84 filas requirió un total de 31.36 s. En 2 000 inferencias escalares realizadas después de 100 ejecuciones de calentamiento, la latencia mediana fue de 2.00 ms y el percentil 95 de 5.66 ms. Estos valores pertenecen exclusivamente al entorno evaluado descrito previamente y muestran que el checkpoint permite interacción de baja latencia. No se realizó un benchmark controlado frente a DSSAT, APSIM o AquaCrop, por lo que no se establece superioridad computacional frente a dichos modelos.

La adaptación mediante el riego debe de evaluarse conjuntamente con la disponibilidad futura del recurso hídrico. Para las áreas agrícolas de los Estados Unidos continentales,

Yang et al. (2026) estimaron que cada incremento de 1 °C en la temperatura por año se asocia con un aumento aproximado de entre el 4.2 % y 5.0 % en los requerimientos de agua para riego. Por tanto, aunque CeresPINN haya identificado el riego deficitario al 75 % como la intervención más favorable en el caso demostrativo, esta recomendación no debe interpretarse de manera aislada: su viabilidad dependerá de la disponibilidad de agua, la eficiencia del sistema de aplicación y la sostenibilidad de las fuentes superficiales o subterráneas pertenecientes a cada condado (Yang et al., 2026).

5.5. Ética y equidad

Las implicaciones sociales o territoriales derivadas de CeresPINN deben de interpretarse con gran cautela. La implementación actual no ha sido calibrada a escala de condado y los perfiles edáficos utilizados no influyen directamente sobre la salida neuronal de rendimiento. En consecuencia, el sistema presente todavía no permite identificar de manera validada qué territorios presentan mayor vulnerabilidad agrícola ni justificar su priorización para políticas públicas, asignación de agua, seguros o financiamiento. Una aplicación de este tipo requeriría de datos espaciales reales, validación de forma independiente, análisis explícito de representatividad geográfica y mecanismos transparentes para cuantificar la incertidumbre real. Hasta ese entonces, las salidas deben utilizarse únicamente con fines exploratorios y de investigación.

Adicionalmente, el sistema presenta tres fuentes de sesgo que deben reconocerse explícitamente. Primero, **sesgo geográfico**: entrenado exclusivamente con datos de Estados Unidos, el modelo no captura la diversidad de sistemas productivos, variedades y condiciones edafoclimáticas de regiones en desarrollo como América Latina o África subsahariana, donde la seguridad alimentaria es más vulnerable. Segundo, **sesgo de escenario**: el entrenamiento incluyó solo tres de los cuatro escenarios SSP prioritarios (excluyó SSP2-4.5), limitando la capacidad del sistema para explorar trayectorias de mitigación intermedias de relevancia política. Tercero, **sesgo de representación varietal**: la respuesta a diferentes cultivos se implementa mediante multiplicadores deterministas en lugar de ser aprendida de datos observados, lo que puede no reflejar la verdadera variabilidad genética disponible para los agricultores. Estas limitaciones refuerzan la recomendación de no utilizar el sistema para la toma de decisiones prescriptivas en contextos no representados en los datos de entrenamiento.

5.6. Limitaciones

Entre las limitaciones tenemos en primer lugar el que CeresPINN no incorpora el análisis de las plagas ni de las enfermedades, así como tampoco a los eventos extremos de corta duración como las granizadas, que no son capturados por los GCM de resolución mensual o diaria (una limitación compartida con otros marcos basados en modelos de cultivo impulsados por datos climáticos diarios; Niu et al., 2026). En segundo lugar, el marco de escenarios climáticos empleado es estático y no representa explícitamente la adaptación autónoma de los agricultores más allá de las intervenciones simuladas, lo que podría sobrestimar el impacto neto proyectado (Xiao et al., 2025). En tercer lugar, la calibración

del componente físico depende tanto de la calidad como de la representatividad de los datos de entrenamiento históricos, por lo que su generalización a otras regiones no representadas en el conjunto de entrenamiento debe interpretarse con mucha cautela.

La fuerte dependencia estructural entre CO₂, heatwave_risk y la codificación del escenario introduce una fuente potencial de confusión en el análisis de sensibilidad. De manera independiente, la degradación observada al sustituir la variable año por su media evidencia una dependencia temporal considerable por parte del predictor.

En cuanto a validez externa, el modelo fue entrenado con objetivos agregados anualmente a escala nacional y evaluado únicamente sobre ocho años independientes, por lo que sus resultados no pueden llegar a generalizarse directamente a otros condados, parcelas, cultivos o sistemas productivos que no se hayan registrado previamente.

Respecto a la validez de constructo, los estados diarios de suelo, fenología y estrés hídrico se calculan mediante un simulador posterior y no intervienen directamente en la predicción base de rendimiento. Por ello, conceptos como vulnerabilidad espacial y respuesta fisiológica integrada todavía se encuentran representados de manera incompleta.

Finalmente, la validez de la conclusión está limitada por el pequeño número de años independientes de prueba. Los amplios intervalos bootstrap, particularmente para el R², indican que las estimaciones puntuales deben interpretarse como evidencia de tipo preliminar del comportamiento del prototipo desarrollado.

Las principales amenazas identificadas, sus posibles efectos sobre la interpretación de los resultados y las medidas de mitigación aplicadas o propuestas se resumen en la Tabla 2.

Tipo	Amenaza	Mitigación realizada	Pendiente
Interna	Redundancia CO ₂ –heatwave–SSP	Correlaciones, Sobol, ablación	Datos climáticos independientes
Externa	36 años agregados, 8 test	Holdout por año	Validación condal/externa
Constructo	Los estados hídricos y fenológicos del simulador no retroalimentan directamente la salida neuronal de rendimiento	Se delimitó explícitamente la separación entre red y simulador y se evitó interpretar el sistema como una PINN de Richards	Acoplar los estados biofísicos al predictor de rendimiento y validar las variables intermedias con observaciones
Conclusión	n=8	Bootstrap 20k, multi-seed	Más años y sitios

Tabla 2. Amenazas frente a la validez del sistema y estrategias de mitigación

5.7 Implicaciones para la Ingeniería de Software e Inteligencia Artificial

Más allá de la aplicación agrícola específica, CeresPINN aporta tres lecciones metodológicas relevantes para los miembros de la comunidad de Ingeniería de Software e IA. Primero, la separación arquitectónica explícita entre un componente aprendido (la red neuronal) y un componente determinista (el simulador biofísico) facilita tanto la capacidad de gestionar auditoría, como a la trazabilidad, pero introduce desacoplamientos estructurales que pueden invalidar interpretaciones causales de las salidas. Este hallazgo llega a ser generalizable a cualquier sistema híbrido de IA en el que los estados simulados no retroalimentan directamente el predictor aprendido. Segundo, la evaluación de la robustez mediante múltiples inicializaciones, remuestreo de tipo bootstrap y pruebas de perturbación de entradas proporciona una visión más completa del comportamiento del sistema que las métricas puntuales tradicionales, específicamente cuando el tamaño de muestra independiente es reducido. Tercero, la identificación explícita de redundancia estadística entre las variables de entrada demuestra que los análisis de sensibilidad global deben interpretarse conjuntamente con análisis de correlación estructural para evitar conclusiones causales erróneas. En conjunto, todas estas lecciones refuerzan la necesidad de marcos de auditoría sistemática para sistemas de IA que operan en dominios críticos donde la transparencia y la validez de nuestro constructo son requerimientos funcionales.

CONCLUSIONES

CeresPINN resalta la factibilidad de cruzar los datos climáticos dentro de una aplicación interactiva que combina, por un lado, una red neuronal físicamente regularizada y, por otro, un simulador diario de fenología y balance hídrico. Para los ocho años individuales reservados en el paradigma de prueba, el rendimiento fue $RMSE = 712,1 \text{ kg ha}^{-1}$, $MAE = 604,2 \text{ kg ha}^{-1}$ y $R^2 = 0,8251$; sumando un rendimiento notoriamente superior al de una red MLP de arquitectura equivalente, entrenada sin regularización en la parte principal del trabajo, y en las diez inicializaciones realizadas para dicha comparación. La regresión lineal y Ridge obtuvieron mejores estimaciones puntuales en el holdout de ocho años, aunque sus diferencias respecto de CeresPINN no resultaron significativas en el análisis bootstrap. De tal manera, la evidenciación soporta el valor de la regularización de monotonidad en la red neuronal utilizada, mas no favorece una superioridad predictiva por sobre modelos de simplicidad mayor.

El caso prueba Iowa-SSP5-8.5-2050 ha permitido contrastar la respuesta a diferentes configuraciones de manejo. El riego deficitario del 75 % ha logrado elevar la producción un 7.29 % en comparación al escenario basal, mientras que el adelanto de siembra no ha modificado el rendimiento y el cultivar de ciclo corto ha disminuido dicho rendimiento. Si se considera que estas intervenciones obedecen a reglas deterministas, se debe interpretar los resultados más bien como exploraciones what-if que como recomendaciones agronómicas optimizadas. La aparente dominancia del CO_2 en el análisis de sensibilidad también debe interpretarse con precaución, debido a su gran redundancia con otras variables codificadas

por escenario. De forma independiente, la prueba de sustitución de la variable "año" mostró una fuerte dependencia temporal del predictor. Ambos hallazgos limitan la interpretación causal y la extrapolación hacia escenarios futuros.

En su estado actual, CeresPINN no resuelve la ecuación de Richards dentro de la red neuronal, no optimiza el manejo de forma autónoma y carece de validación espacial o externa independiente. Su valor reside en ser un prototipo híbrido, trazable y reproducible, respaldado por una evaluación controlada de la regularización de monotonicidad, el análisis con múltiples semillas, la cuantificación de la incertidumbre y la descripción explícita de sus limitaciones estructurales.

Los resultados también señalan las mejoras necesarias para que CeresPINN avance hacia un gemelo digital agrícola plenamente validado: conservar la ventaja frente al MLP sin regularización, ampliar la evidencia comparativa con modelos lineales, reducir la redundancia entre variables de escenario y acoplar el simulador diario con la cabeza de rendimiento.

Y su alcance no es sólo desde el ámbito agrícola; estas conclusiones dan cuenta de que los sistemas híbridos de IA necesitan auditoría sistemática porque separar componentes aprendidos de los deterministas puede esconder limitaciones de constructo que sólo métricas de desempeño predictivo en profundidad no logran mostrar.

Declaración de uso de inteligencia artificial generativa

Durante la preparación de este manuscrito se utilizó OpenAI Codex como apoyo para la auditoría de código, la elaboración de scripts reproducibles, la revisión de consistencia metodológica y corrección lingüística aplicada a los conceptos complejos. La herramienta no sustituyó la ejecución de los experimentos ni la interpretación científica de sus resultados. Los autores revisaron el código, verificaron las métricas obtenidas y asumen responsabilidad íntegra por el contenido final.

Consideraciones éticas

El estudio utilizó datos agronómicos y climáticos públicos y no involucró participantes humanos, animales, historias clínicas ni intervenciones experimentales sobre seres vivos. Por ello, no requirió aprobación de un comité de ética. El prototipo se desarrolló con fines de investigación y no debe utilizarse directamente para decisiones automatizadas de crédito, seguros, asignación de agua u otras decisiones de alto impacto.

Disponibilidad de código y datos

El código fuente de CeresPINN, el checkpoint entrenado, los metadatos de normalización, las tablas procesadas utilizadas por los scripts de reproducibilidad y los scripts de análisis están disponibles en el repositorio público: <https://github.com/David42024/CeresPINN> (commit 725570d3d9920dd08c395296bd5169762edc66d4, licencia MIT). El proyecto incluye un Dockerfile para construir y ejecutar el backend productivo mediante `docker build` y `docker run`.

Reproducibilidad: El repositorio incluye dependencias Python fijadas en requirements-repro.txt, verificaciones de integridad SHA-256 y un script automatizado, scripts/reproduce.py, que reproduce los artefactos de auditoría y validación enumerados en el manifiesto, sin requerir claves de API, una base de datos ni descargas adicionales de datos. El workflow de GitHub Actions permite ejecutar manualmente este proceso y publicar los artefactos resultantes. Los artefactos existentes pueden verificarse sin reentrenar mediante `python scripts/reproduce.py --verify-only`.

Arquitectura: Frontend (React + Vite + TypeScript), backend (FastAPI + Python), motor de simulación híbrido (red neuronal PyTorch con regularización de monotonicidad y simulador determinista diario), persistencia (PostgreSQL/PostGIS con fallback mock para desarrollo) y asistente conversacional (Google Gemini API, utilizado únicamente para la interfaz de chat, nunca para predicciones agrícolas).

Limitaciones explícitas: La red neuronal no resuelve la ecuación de Richards; las comparaciones espaciales de campo son exploratorias, pues las coordenadas y los parámetros del suelo no son entradas de la red; y la validación temporal prospectiva mostró una capacidad de extrapolación débil.

Conflictos de interés

Los autores declaran no tener conflictos de interés relacionados con la realización, los resultados o la publicación de este estudio.

Financiamiento

Esta investigación no recibió financiamiento específico de organismos públicos, comerciales ni de organizaciones sin fines de lucro. El desarrollo del estudio fue realizado con recursos propios de los autores.

REFERENCIAS

Abramoff, R. Z., Ciais, P., Zhu, P., Hasegawa, T., Wakatsuki, H., & Makowski, D. (2023). Adaptation strategies strongly reduce the future impacts of climate change on simulated crop yields. *Earth's Future*, 11, e2022EF003190. <https://doi.org/10.1029/2022EF003190>

Alimagham, S., van Loon, M. P., Ramirez-Villegas, J., Berghuijs, H. N. C., Rosenstock, T. S., & van Ittersum, M. K. (2025). Integrating crop models and machine learning for projecting climate change impacts on crops in data-limited environments. *Agricultural Systems*. <https://doi.org/10.1016/j.agry.2025.104367>

Alsilibe, F., Bene, K., Bilal, G., Alghafli, K., & Shi, X. (2023). Accuracy assessment and validation of multi-source CHIRPS precipitation estimates for water resource management in the Barada Basin, Syria. *Remote Sensing*, 15, 1778. <https://doi.org/10.3390/rs15071778>

Chavoshi, A., Dashtian, H., Bakhshian, S., Young, M. H., & Niyogi, D. (2024). PINN-SM: A physics-informed neural networks model for vadose zone soil moisture profile prediction. *Journal of Geophysical Research: Machine Learning and Computation*, 2, e2024JH000547. <https://doi.org/10.1029/2024JH000547>

Cheng, M., Peñuelas, J., McCabe, M. F., Atzberger, C., Jiao, X., Wu, W., & Jin, X. (2022). Combining multi-indicators with machine-learning algorithms for maize yield early prediction at the county-level in China. *Agricultural and Forest Meteorology*, 323, 109057. <https://doi.org/10.1016/j.agrformet.2022.109057>

de Souza, E. B., et al. (2026). Projected heatwave hazards in an eastern Amazonian metropolis under contrasting CMIP6 scenarios. *Scientific Reports*. <https://doi.org/10.1038/s41598-026-57944-x>

Dokoohaki, H., Rai, T., Kivi, M., Lewis, P., Gómez-Dans, J. L., & Yin, F. (2022). Linking remote sensing with APSIM through emulation and Bayesian optimization to improve yield prediction. *Remote Sensing*, 14, 5389. <https://doi.org/10.3390/rs14215389>

Escribà-Gelonch, M., Liang, S., van Schalkwyk, P., Fisk, I., Long, N. V. D., & Hessel, V. (2024). Digital twins in agriculture: Orchestration and applications. *Journal of Agricultural and Food Chemistry*, 72(19), 10737–10752. <https://doi.org/10.1021/acs.jafc.4c01934>

Eyring, V., Bony, S., Meehl, G. A., Senior, C. A., Stevens, B., Stouffer, R. J., & Taylor, K. E. (2016). Overview of the Coupled Model Intercomparison Project Phase 6 (CMIP6) experimental design and organization. *Geoscientific Model Development*, 9, 1937–1958. <https://doi.org/10.5194/gmd-9-1937-2016>

Farea, A., Yli-Harja, O., & Emmert-Streib, F. (2024). Understanding physics-informed neural networks: Techniques, applications, trends, and challenges. *AI*, 5(3), 1534–1557. <https://doi.org/10.3390/ai5030074>

Galmarini, S., Solazzo, E., Ferrise, R., Srivastava, A. K., et al. (2024). Assessing the impact on crop modelling of multi- and uni-variate climate model bias adjustments. *Agricultural Systems*, 216, 103846. <https://doi.org/10.1016/j.agry.2023.103846>

Granella, S. J. (2026). Anomalous diffusion in drying: A fractional calculus perspective on modeling and applications in agro-food systems. *Food Physics*. <https://doi.org/10.1016/j.foodp.2026.100088>

Han, Y., Wang, K., Yang, F., Pan, S., Liu, Z., Zhang, Q., & Zhang, Q. (2024). Prediction of maize cultivar yield based on machine learning algorithms for precise promotion and planting. *Agricultural and Forest Meteorology*, 355, 110123. <https://doi.org/10.1016/j.agrformet.2024.110123>

Hlavinka, P., Trnka, M., Balek, J., Semerádová, D., Hayes, M., Svoboda, M., Eitzinger, J., Možný, M., Fischer, M., Hunt, E., & Žalud, Z. (2017). Impacts of water availability and drought on maize yield: A comparison of 16 indicators. *Agricultural Water Management*. <https://doi.org/10.1016/j.agwat.2017.04.007>

Jägermeyr, J., Müller, C., Ruane, A. C., Elliott, J., Balkovic, J., Castillo, O., et al. (2021). Climate impacts on global agriculture emerge earlier in new generation of climate and crop models. *Nature Food*, 2(11), 873–885. <https://doi.org/10.1038/s43016-021-00400-y>

Maraun, D., Wetterhall, F., Ireson, A. M., Chandler, R. E., Kendon, E. J., Widmann, M., et al. (2010). Precipitation downscaling under climate change: Recent developments to bridge the gap between dynamical models and the end user. *Reviews of Geophysics*, 48(3), RG3003. <https://doi.org/10.1029/2009RG000314>

Mbengue, A., Sultan, B., Lguensat, R., Vrac, M., Diongue-Niang, A., Ndiaye, O., & Gaye, A. T. (2026). High-resolution downscaled CMIP6 projections dataset of key climate variables for Senegal. *Scientific Data*. <https://doi.org/10.1038/s41597-026-07059-9>

Melesse, T. Y. (2025). Digital twin-based applications in crop monitoring. *Heliyon*, 11(2), e42137. <https://doi.org/10.1016/j.heliyon.2025.e42137>

Minoli, S., Jägermeyr, J., Asseng, S., Urfels, A., & Müller, C. (2022). Global crop yields can be lifted by timely adaptation of growing periods to climate change. *Nature Communications*, 13, 7079. <https://doi.org/10.1038/s41467-022-34411-5>

Miranda, M., Charfuelan, M., Valdenegro-Toro, M., & Dengel, A. (2025). Informed learning for estimating drought stress at fine-scale resolution enables accurate yield prediction. In *ECAI 2025, Frontiers in Artificial Intelligence and Applications* (Vol. 413, pp. 5384–5391). <https://doi.org/10.3233/FAIA251477>

Niu, X., Yang, Z., Zhang, J., Sun, X., Liu, Z., Jin, S., Cai, J., Zhang, B., & Sun, Y. (2026). Optimizing sowing date and nitrogen management to trade off yield and nitrate leaching in maize-soybean intercropping under CMIP6 climate scenarios in the North China Plain. *Plants*, 15, 1753. <https://doi.org/10.3390/plants15111753>

O'Neill, B. C., Tebaldi, C., van Vuuren, D. P., Eyring, V., Friedlingstein, P., et al. (2016). The Scenario Model Intercomparison Project (ScenarioMIP) for CMIP6. *Geoscientific Model Development*, 9, 3461–3482. <https://doi.org/10.5194/gmd-9-3461-2016>

Pukrongta, N., Taparugssanagorn, A., & Sangpradit, K. (2023). Assessing a machine learning model for predicting maize grain yield based on chlorophyll content and vegetation indices. In *2023 International Conference on Power, Energy and Innovations (ICPEI)*. IEEE. <https://ieeexplore.ieee.org/document/10473794>

Purcell, W., Neubauer, T., & Mallinger, K. (2023). Digital twins in agriculture: Challenges and opportunities for environmental sustainability. *Current Opinion in Environmental Sustainability*, 61, 101252. <https://doi.org/10.1016/j.cosust.2022.101252>

Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707. <https://doi.org/10.1016/j.jcp.2018.10.045>

Sakthivel, S., Pazhanivelan, S., Thiruvavarsan, S., Prabu, P. C., Gnanachitra, M., Rahale, C. S., Sivamurugan, A. P., Ragunath, K. P., & Satheesh, S. (2025). A comprehensive bibliometric review of DSSAT applications in maize yield prediction. *Maydica*, 68(1). <https://creajournals.crea.gov.it/index.php/maydica/article/view/2633>

Shahhosseini, M., Hu, G., Huber, I., & Archontoulis, S. V. (2021). Coupling machine learning and crop modeling improves crop yield prediction in the US Corn Belt. *Scientific Reports*, 11, 1606. <https://doi.org/10.1038/s41598-020-80820-1>

Shi, Y., Han, L., Zhang, X., Sobeih, T., Gaiser, T., Thuy, N. H., Behrend, D., Srivastava, A. K., Halder, K., & Ewert, F. (2025). Deep learning meets process-based models: A hybrid approach to agricultural challenges [Preprint]. *arXiv*. <https://doi.org/10.48550/arXiv.2504.16141>

Shi, Y., Han, L., Zhang, X., Sobeih, T., Gaiser, T., Thuy, N. H., Behrend, D., Srivastava, A. K., Halder, K., & Ewert, F. (2026). AgriPINN: A process-informed neural network for interpretable and scalable crop biomass prediction under water stress [Preprint]. *arXiv*. <https://doi.org/10.48550/arXiv.2601.16045>

Thrasher, B., Wang, W., Michaelis, A., Melton, F., Lee, T., & Nemani, R. (2022). NASA global daily downscaled projections, CMIP6. *Scientific Data*, 9, 262. <https://doi.org/10.1038/s41597-022-01393-4>

Uscamayta-Ferrano, E., et al. (2025). CHIRTS gridded air temperature downscaling integrating machine learning and physical constraints. *Atmosphere*, 16, 1188. <https://doi.org/10.3390/atmos16101188>

Wakatsuki, H., Ju, H., Nelson, G. C., Farrell, A. D., Deryng, D., Meza, F., & Hasegawa, T. (2023). Research trends and gaps in climate change impacts and adaptation potentials in major crops. *Current Opinion in Environmental Sustainability*, 61, 101249. <https://doi.org/10.1016/j.cosust.2022.101249>

Xiao, K., Zhou, X., Gui, H., Tian, Y., Chen, X., Li, Y., Matomela, N., & Xin, Q. (2025). Drought and extreme heat reduce wheat and maize production in the United States by

lowering both crop yields and harvestable fraction. *Earth's Future*, 13, e2024EF005557.
<https://doi.org/10.1029/2024EF005557>

Xu, C., Torres-Rojas, L., Vergopolan, N., & Chaney, N. W. (2023). The benefits of using state-of-the-art digital soil properties maps to improve the modeling of soil moisture in land surface models. *Water Resources Research*, 59, e2022WR032336.
<https://doi.org/10.1029/2022WR032336>

Xu, Q., Liang, H., Wei, Z., et al. (2024). Assessing climate change impacts on crop yields and exploring adaptation strategies in Northeast China. *Earth's Future*, 12, e2023EF004063.
<https://doi.org/10.1029/2023EF004063>

Xu, X., Gao, F., Du, X., Xiong, D., Fan, Z., Xiong, S., Dong, P., Qiao, H., & Ma, X. (2025a). Digital twin-based winter wheat growth simulation and optimization. *Field Crops Research*, 329, 109953. <https://doi.org/10.1016/j.fcr.2025.109953>

Yang, H., Yang, J., Ochsner, T. E., Zhang, Q., Jiao, X., Fang, S., Zhou, Y., & Zou, C. B. (2026). Increasing irrigation water requirements across croplands in the contiguous United States throughout the 21st century. *Agricultural Water Management*.
<https://doi.org/10.1016/j.agwat.2025.110044>

Yu, D., Zha, Y., Zeng, Y., Lai, P., Zhu, W., Bian, J., Yang, Q., Huang, X., & Su, Z. (2025). An efficient and physics-informed regional maize yield estimation scheme by combining data assimilation and machine learning. *Computers and Electronics in Agriculture*.
<https://doi.org/10.1016/j.compag.2025.111142>

Zhang, H., Zhao, J., Hong, M., & Ma, L. (2025a). Optimization of deficit irrigation system for drip-irrigated corn in northern Xinjiang using dynamic reconstruction and dual physics-informed neural networks to drive AquaCrop. *Frontiers in Plant Science*.
<https://doi.org/10.3389/fpls.2025.1678277>

Zhang, L., Bai, G., Evett, S. R., Colaizzi, P. D., Xue, Q., Marek, G., Dhungel, R., Zhao, H., Wan, N., & Lin, X. (2025b). Increased irrigation could mitigate future warming-induced maize yield losses in the Ogallala Aquifer. *Communications Earth & Environment*, 6, 483.
<https://doi.org/10.1038/s43247-025-02459-y>

Zhang, R., Zhu, H., Chang, Q., & Mao, Q. (2025c). A comprehensive review of digital twins technology in agriculture. *Agriculture*, 15(9), 903.
<https://doi.org/10.3390/agriculture15090903>