

Plan de implementación para reentrenamiento y consumo de predicciones en CeresPinn

Documento técnico de ejecución

Versión 1.0

Fecha 25 de septiembre de 2026

Repositorio evaluado `cerespinn climate adaptive maize digital twin`

Commit de referencia `8bf6d695a9683231ef8710efa32bd149691bf78b`

Decisión y propósito

CeresPinn puede reemplazar el modelo actual por un modelo supervisado convencional y mantener el mismo flujo React, FastAPI y artefacto de inferencia. La implementación recomendada no debe volver a entrenar otra red sobre la matriz actual de 108 filas y tratar el resultado como una predicción parcelaria. Debe reconstruir primero un panel histórico condado-año, entrenar modelos tabulares con validación temporal y geográfica, y separar las predicciones aprendidas de las variables generadas por el simulador determinista.

Este plan establece el trabajo necesario para producir un modelo de rendimiento anual condicionado por clima, integrarlo en el gemelo digital, cuantificar su incertidumbre y mostrar su alcance real en el frontend. También define una ruta provisional si no es posible recuperar inmediatamente los identificadores espaciales y las series climáticas históricas por condado.

El resultado esperado es un sistema en el que cada cifra indique si procede del modelo entrenado, del balance hídrico determinista o de un cálculo derivado. La promoción a producción dependerá de pruebas prospectivas. Un buen ajuste en una partición aleatoria no será suficiente.

Resumen del estado actual

El archivo `data/cerespinn_training_iowa.csv` tiene 66 480 filas y nueve columnas, pero representa 22 160 rendimientos NASS repetidos para tres escenarios SSP. Solo contiene 36 años independientes, desde 1990 hasta 2025. El pipeline de entrenamiento calcula una mediana anual y replica el mismo objetivo para SSP1-2.6, SSP3-7.0 y SSP5-8.5. El modelo termina usando 84 filas de entrenamiento y 24 de prueba, equivalentes a 28 y 8 años independientes.

El dataset procesado no conserva estado, condado, FIPS ni coordenadas. Los tres escenarios tienen solo tres valores de CO2, precipitación anómala y riesgo de ola de calor. `seasonal_cdd` es constante. Por tanto, el modelo no puede distinguir localidades ni aprender una respuesta observada a los SSP futuros.

La validación prospectiva existente entrena con 1990 a 2017 y evalúa 2018 a 2025. El ensamble neuronal obtiene R2 negativo. Random Forest queda cerca de R2 cero y Ridge también obtiene R2 negativo. Estos resultados no invalidan las fuentes de datos, pero muestran que la representación actual no demuestra capacidad de pronóstico futuro.

Elemento	Estado actual	Implicación
Rendimiento observado	USDA NASS con 22 160 observaciones originales	La agregación actual descarta la variación espacial
Clima	Resumen regional NASA NEX GDDP y plantillas SSP	No existe emparejamiento histórico por condado en el CSV final
Unidades independientes	36 años	Insuficiente para justificar una red profunda compleja
Escenarios	Tres copias del mismo rendimiento anual	No permiten aprender el efecto causal de SSP1 frente a SSP5
Manejo	Sin targets observados de riego variedad o nitrógeno	Los efectos actuales son multiplicadores programados
Estados diarios	Sin observaciones de humedad LAI biomasa o CWSI	La serie diaria es una simulación determinista
Consumo frontend	Funcional mediante <code>/api/simulate</code>	El contrato exige actualmente <code>inference_mode=pinn</code>

Alcance del producto objetivo

Capacidad que debe implementarse

La versión siguiente debe predecir rendimiento anual de maíz en kg por hectárea para una unidad espacial y un conjunto de variables climáticas compatibles con el entrenamiento. Debe devolver un intervalo predictivo, versión del modelo, procedencia del dataset, indicador de extrapolación y alcance geográfico.

Cuando el panel condado-año esté disponible, la unidad espacial será el condado. Mientras solo existan los archivos procesados actuales, la unidad será regional y la salida deberá etiquetarse como exploratoria.

Capacidades que deben permanecer separadas

El balance hídrico de tres capas puede seguir generando humedad, evapotranspiración, drenaje y estrés diario, pero deberá identificarse como simulación determinista. No se debe afirmar que esos valores fueron aprendidos por el modelo de rendimiento.

Los efectos de variedad, riego y nitrógeno deben retirarse de la predicción aprendida hasta disponer de ensayos u observaciones que contengan esas variables y un rendimiento asociado. Pueden mantenerse como escenarios heurísticos si la interfaz los distingue de una recomendación agronómica validada.

La comparación territorial y la predicción parcelaria deberán permanecer deshabilitadas hasta completar una validación espacial independiente.

Criterio de éxito

El proyecto estará listo para producción exploratoria cuando un modelo seleccionado supere baselines simples en evaluación temporal prospectiva, mantenga trazabilidad reproducible, detecte entradas fuera de dominio y sea consumido por React sin falsificar su tipo o procedencia. Si no supera el baseline, el pipeline debe conservar los resultados como investigación y no reemplazar el modelo activo.

Arquitectura objetivo

Capa	Responsabilidad	Salida principal
Ingesta	Descargar y versionar NASS clima histórico y proyecciones CMIP6	Archivos crudos inmutables y manifiestos
Curación	Emparejar condado año clima suelo y rendimiento	Panel canónico validado
Entrenamiento	Comparar baselines modelos tabulares y MLP pequeña	Modelo candidato y métricas prospectivas
Registro	Guardar artefacto esquema hashes normalización y dominio	Paquete versionado de modelo
Inferencia FastAPI	Validar entradas predecir intervalo y detectar extrapolación	Respuesta JSON con procedencia
Simulador	Ejecutar balance hídrico y cálculos derivados	Serie diaria identificada como determinista
Frontend React	Mostrar resultado fuente incertidumbre y limitaciones	Interfaz auditable

El servicio de inferencia debe exponer una interfaz neutral. El nombre `PinnInference` debe reemplazarse gradualmente por `YieldInferenceService`. El backend podrá cargar un artefacto de scikit-learn o PyTorch sin cambiar el contrato de negocio.

Estrategias de implementación

Ruta A con los archivos actuales

Esta ruta permite construir una versión regional en poco tiempo. El entrenamiento debe reducir el dataset a 36 observaciones anuales y eliminar la falsa multiplicación de unidades por escenario. Se compararán modelos simples y se informará que las proyecciones posteriores a 2025 son extrapolaciones.

La ruta A sirve para estabilizar el pipeline, el registro, la API, los tests y el frontend. No habilita predicción por condado, manejo agronómico aprendido ni priorización territorial.

Ruta B recomendada con las fuentes actuales

Esta ruta vuelve a descargar o reconstruir los datos NASS preservando estado, condado y FIPS. Después agrega clima histórico por condado-año y, cuando sea posible, propiedades edáficas reales. Así se recuperan miles de unidades observacionales con variación espacial y temporal.

El modelo aprende la relación entre clima histórico y rendimiento observado. Las proyecciones futuras se obtienen aplicando exactamente la misma ingeniería de variables a cada miembro CMIP6. Los SSP no se usan como etiquetas de entrenamiento ni se replica el rendimiento histórico como si hubiera ocurrido bajo tres futuros distintos.

Ruta C para un gemelo diario calibrado

Esta ruta requiere datasets adicionales de humedad del suelo, biomasa, LAI, fenología, riego, nitrógeno y rendimiento a nivel de parcela o ensayo. No forma parte del reentrenamiento inicial. Debe tratarse como una línea posterior de investigación y validación.

Ruta	Resultado	Uso permitido	Recomendación
A	Rendimiento regional anual	Demostración e investigación	Ejecutar primero para estabilizar el sistema
B	Rendimiento por condado con clima histórico y CMIP6	Exploración regional con validación espacial	Objetivo principal
C	Estados diarios y respuesta a manejo aprendida	Gemelo parcelario sujeto a datos y validación	Trabajo futuro

Fase 0 congelar y documentar la línea base

Objetivo

Preservar el checkpoint, datasets, métricas y comportamiento actual para que toda mejora pueda compararse y revertirse.

Actividades

1. Crear una etiqueta Git para la versión actual y registrar el commit de referencia.
2. Calcular SHA-256 de los CSV, checkpoint, metadata y artefactos Q1.
3. Guardar las respuestas de [/api/model/status](#) y [/api/simulate](#) para un conjunto fijo de casos.
4. Ejecutar la suite de tests Python y TypeScript y conservar sus resultados.
5. Registrar el rendimiento actual en holdout aleatorio y validación 2018 a 2025.
6. Crear un manifiesto de dependencias y semillas.

Entregables

- [reproducibility/baseline_v2_manifest.json](#)
- Casos de inferencia dorados en [tests/fixtures/model_v2](#)
- Etiqueta o rama de respaldo de producción
- Informe comparativo inicial

Criterios de aceptación

- El checkpoint actual puede restaurarse sin depender de archivos externos no versionados.
- Los hashes y métricas se reproducen en una ejecución limpia.
- Existe un procedimiento de rollback documentado.

Fase 1 definir el contrato canónico de datos

Objetivo

Establecer una fila observacional que conserve identidad espacial, tiempo, variables predictoras y target sin duplicación artificial.

Esquema mínimo recomendado

Campo	Tipo	Regla
year	entero	Año de cosecha observado
state_fips	texto	Identificador estable del estado
county_fips	texto	Identificador estable del condado
state_name	texto	Etiqueta informativa
county_name	texto	Etiqueta informativa
latitude longitude	decimal	Centroide o geometría de referencia documentada
yield_bu_acre	decimal	Target NASS limpio
season_temp_mean_c	decimal	Clima histórico de la estación agrícola
season_tmax_mean_c	decimal	Máxima media estacional
season_precip_mm	decimal	Precipitación acumulada
gdd	decimal	Grados día con fórmula versionada
cdd	decimal	Días secos consecutivos con umbral versionado
heat_days_30c	entero	Días sobre 30 grados Celsius
heat_days_35c	entero	Días sobre 35 grados Celsius
vpd_mean_kpa	decimal	Si la fuente permite calcularlo
soil_source	texto	Fuente del perfil edáfico cuando exista
data_quality_flags	texto	Ausencias interpolación y anomalías

Reglas obligatorias

- Una observación histórica tendrá un único target.
- Los SSP futuros no duplicarán targets históricos.
- Toda imputación incluirá una bandera.
- Las unidades se convertirán en una sola etapa reproducible.
- Los límites de la estación agrícola se definirán por región o mediante una regla documentada.
- Las columnas categóricas usarán códigos estables además de nombres.

Archivos que deben cambiar

- `backend/training/dataset.py` para abandonar la mediana anual como dataset principal.
- `backend/training/config.py` para declarar esquema, columnas y versiones.
- `backend/data/nass.py` para preservar FIPS y atributos espaciales.
- `backend/data/nex_gddp.py` y `backend/data/chirps.py` para producir agregados por unidad espacial.

Criterios de aceptación

- Una prueba detecta duplicación del mismo target bajo SSP distintos.
- Cada fila puede trazarse hasta un registro NASS y archivos climáticos concretos.
- El panel incluye un diccionario de datos y un reporte de calidad.

Fase 2 reconstruir el panel histórico

Paso 1 recuperar rendimiento NASS

Ejecutar el extractor en modo real con una clave NASS válida y `CERESPINN_DRY_RUN=0`. La descarga debe preservar año, estado, condado, FIPS, unidad, descripción de la variable y valor original. Los registros deben almacenarse como artefactos crudos inmutables antes de la limpieza.

Paso 2 normalizar rendimiento

Convertir valores a numérico, resolver símbolos de supresión, unificar unidades y eliminar duplicados exactos. No se deben combinar condados hasta después de crear el panel. Los outliers no deben eliminarse automáticamente; se marcarán para revisión y se compararán reglas robustas.

Paso 3 construir clima histórico

Para el periodo observado se debe utilizar clima histórico, no plantillas SSP. Agregar temperatura, precipitación, GDD, CDD y extremos para la estación de cultivo de cada condado-año. Si NEX-GDDP histórico no cubre todos los años con calidad suficiente, se debe incorporar una fuente observacional o de reanálisis compatible y documentar el cambio.

Paso 4 incorporar proyecciones

Procesar CMIP6 por escenario, modelo climático, condado y año futuro. Conservar el identificador del GCM. No resumir todos los modelos antes de inferencia. La distribución entre miembros se utilizará para cuantificar incertidumbre climática.

Paso 5 incorporar suelo cuando sea verificable

No usar los cuatro perfiles codificados del frontend como evidencia espacial. Si se incorpora suelo, cada condado o geometría debe enlazarse a una fuente externa documentada y a variables que tengan cobertura consistente. La primera versión puede excluir suelo si la cobertura no es adecuada.

Paso 6 producir el panel canónico

Guardar el panel en Parquet para preservar tipos y reducir tamaño. Crear además una muestra CSV legible y un manifiesto JSON con hashes, fuentes, periodo, número de condados, años, porcentaje de datos faltantes y transformaciones.

Criterios de aceptación

- No existen filas con el mismo condado, año y target repetidas por escenario.
- La cobertura temporal y espacial se publica por variable.
- Se identifican explícitamente años y condados sin clima suficiente.
- Las proyecciones CMIP6 se almacenan separadas del dataset histórico de entrenamiento.

Fase 3 ingeniería de variables

Variables permitidas para el primer modelo

El primer modelo utilizará solo variables disponibles tanto en el entrenamiento histórico como en la inferencia futura. Se priorizarán acumulados y extremos estacionales. El año podrá incluirse como tendencia tecnológica, pero deberá compararse contra un modelo sin año para medir cuánto desempeño procede de la tendencia y cuánto del clima.

Variables que deben excluirse inicialmente

- Etiqueta SSP como predictor directo.
- CO2 si solo tiene tres valores de plantilla y no una serie histórica coherente.
- Riesgo de ola de calor codificado por escenario.
- `seasonal_cdd` constante.
- Variables de manejo sin observaciones asociadas.
- Identificadores textuales de condado sin una estrategia validada de codificación.

Prevención de fuga de información

Las estadísticas de normalización, imputación, selección de variables y codificación se ajustarán solo con el conjunto de entrenamiento dentro de cada fold. Las transformaciones deben formar parte de un [Pipeline](#) de scikit-learn o equivalente para evitar aplicar información del periodo de prueba.

Diagnósticos requeridos

- Distribución y cobertura por variable.
- Matriz de correlaciones y varianza.
- Dependencia con el año.
- Comparación de clima histórico y clima futuro para detectar extrapolación.
- Importancia por permutación calculada solo en validación.
- Pruebas de estabilidad ante exclusión de una variable.

Fase 4 diseñar la validación

División temporal principal

La evaluación principal debe simular el uso futuro. Un diseño inicial conservará 1990 a 2017 para entrenamiento y 2018 a 2025 para prueba final. Durante desarrollo se utilizará validación rolling-origin dentro de 1990 a 2017.

Validación espacial

Cuando exista el panel condado-año, se reservarán estados o grupos de condados completos. El modelo no debe ver la misma unidad espacial en entrenamiento y prueba para la evaluación espacial. Se reportarán por separado desempeño temporal, espacial y espacio-temporal.

Baselines obligatorios

1. Media histórica de entrenamiento.
2. Rendimiento del año anterior cuando esté disponible.
3. Tendencia lineal por año.
4. Ridge con variables climáticas.
5. Random Forest o HistGradientBoosting regularizado.

Un modelo neuronal solo podrá seleccionarse si mejora consistentemente estos baselines en los periodos y territorios reservados.

Métricas

Métrica	Uso
MAE kg por hectárea	Error típico interpretable
RMSE kg por hectárea	Penalización de errores grandes
R2	Comparación con variabilidad del conjunto de prueba
Sesgo medio	Tendencia a sobreestimar o subestimar
Cobertura del intervalo	Proporción dentro del intervalo predictivo
Anchura del intervalo	Utilidad de la incertidumbre reportada
Error por región y cuantil	Equidad y estabilidad geográfica

Regla de promoción

El candidato debe mejorar el baseline operativo en MAE y RMSE sobre el holdout temporal y no degradarse de forma material en la validación espacial. El R2 prospectivo debe ser positivo para declarar habilidad predictiva frente a una referencia constante. Si no cumple, el sistema conservará el modelo como experimental y mostrará esa clasificación.

No se debe ajustar el modelo después de observar repetidamente el conjunto 2018 a 2025. Si se usa para decisiones de arquitectura, será necesario reservar un nuevo conjunto final o aplicar validación anidada.

Fase 5 entrenar y seleccionar modelos

Experimento A modelos simples

Entrenar regresión lineal, Ridge y Elastic Net con un pipeline completo de imputación, escalado y estimación. Estos modelos establecen una referencia interpretable y permiten detectar si la señal principal es solo tendencia temporal.

Experimento B modelos de árboles

Entrenar Random Forest, Extra Trees y HistGradientBoosting con límites de profundidad, tamaño mínimo de hoja y búsqueda de hiperparámetros dentro de los folds temporales. Los árboles no deben validarse mediante KFold aleatorio sobre filas mezcladas.

Experimento C red neuronal pequeña

Entrenar una MLP pequeña solo después de establecer baselines. La arquitectura debe ser proporcional al número de unidades independientes. Se probarán dropout, weight decay y early stopping. La regularización monótonica puede conservarse como experimento, pero deberá describirse como restricción de forma y no como residual físico.

Selección

La selección se realizará por una tabla predefinida que combine MAE temporal, RMSE temporal, sesgo, estabilidad entre seeds, desempeño espacial y cobertura de intervalos. El nombre del modelo no tendrá peso en la decisión.

Reproducibilidad

Cada corrida registrará commit, hash del dataset, seed, versiones de dependencias, hiperparámetros, duración, métricas por fold y ruta del artefacto. Las mejores corridas se guardarán en un registro de modelos inmutable.

Entregables

- `backend/training_v3` o refactor equivalente
- Tabla comparativa de modelos
- Predicciones out of fold
- Reporte de errores por año y región
- Artefacto candidato no promovido

Fase 6 incertidumbre y detección de extrapolación

Incetidumbre del modelo

Calibrar intervalos sobre predicciones out of fold. Puede utilizarse conformal prediction o un ensamble de seeds si se demuestra cobertura adecuada. El intervalo debe reflejar incertidumbre del modelo y no confundirse con dispersión climática.

Incetidumbre climática

Ejecutar inferencia para cada miembro GCM y escenario disponible. Reportar mediana, cuartiles y rango del ensamble real. El frontend no debe mostrar “32 modelos” si no existen 32 artefactos procesados en la solicitud.

Fuera de dominio

Guardar en metadata mínimos, máximos, cuantiles y distribución de cada variable de entrenamiento. La inferencia marcará una entrada como extrapolación cuando exceda el dominio configurado. También se evaluará distancia multivariable mediante un método sencillo y reproducible.

Respuesta esperada

Una respuesta futura debe distinguir:

- Intervalo por incertidumbre del modelo.
- Dispersión entre GCM.
- Bandera de extrapolación.
- Alcance espacial y temporal validado.

Fase 7 empaquetar el modelo

Contenido del paquete

El artefacto de producción incluirá el estimador, pipeline de transformación, esquema de entrada, metadata, hashes, métricas, dominio de variables y ejemplos dorados. Para scikit-learn puede utilizarse [joblib](#) con versiones fijadas. Para PyTorch se conservarán pesos y configuración explícita.

Metadata mínima

Campo	Contenido
model_name	Nombre neutral sin afirmar PINN
model_version	Versión semántica
framework	scikit-learn o PyTorch
dataset_sha256	Hash del panel de entrenamiento

Campo	Contenido
feature_schema_version	Versión del contrato
train_period	Periodo usado para ajuste
validation_period	Periodo prospectivo
geographic_scope	Región o condados cubiertos
metrics	Temporal espacial e intervalos
training_commit	Commit de código
created_at	Fecha UTC
limitations	Restricciones de uso

Promoción atómica

El modelo nuevo se guardará con un nombre versionado. Un alias o archivo de manifiesto señalará la versión activa. La promoción cambiará el alias solo después de superar tests. El checkpoint anterior permanecerá disponible para rollback.

Fase 8 integrar FastAPI

Refactor del servicio

Crear una interfaz `YieldModelAdapter` con métodos para cargar, validar esquema, predecir y devolver incertidumbre. Implementar adaptadores separados para el checkpoint actual y el nuevo modelo. `YieldInferenceService` seleccionará el adaptador desde configuración.

Cambios en el endpoint

`POST /api/simulate` continuará componiendo la predicción anual con el simulador diario. La respuesta separará cada procedencia. No se reutilizará `inference_mode=pinn` para un modelo que no sea PINN.

Contrato propuesto

```
{
  "inference_mode": "trained_ml",
  "model_name": "CeresYield",
  "model_version": "3.0.0",
  "model_verified": true,
  "prediction_scope": "county_annual",
  "model_data_source": "USDA NASS plus historical climate",
  "dataset_sha256": "hash",
  "projected_yield_kg_ha": 9200,
  "prediction_interval_90": {
    "lower_kg_ha": 7800,
    "upper_kg_ha": 10600
  },
  "is_extrapolation": false,
  "extrapolated_features": [],
  "component_provenance": {
    "yield": "trained_model",
    "daily_records": "deterministic_water_balance",
    "economics": "derived_formula",
    "management_effect": "not_learned"
  }
}
```

```
    },  
    "daily_records": []  
  }  
}
```

Validación de entrada

El backend rechazará combinaciones imposibles, valores faltantes y unidades incorrectas. Para datos fuera del dominio podrá responder con predicción marcada como extrapolación o rechazarla según la severidad. La decisión deberá ser configurable y quedar registrada.

Compatibilidad

Durante la transición se mantendrá el adaptador v2 y se agregará un parámetro interno para ejecutar v2 y v3 en paralelo. El frontend recibirá v3 solo cuando el contrato esté completo. No se ejecutará fallback sintético silencioso en producción.

Fase 9 integrar React

Cambios en el cliente API

Modificar `src/services/api.ts` para validar `model_verified`, `model_version`, alcance, intervalo y procedencia, en vez de exigir `inference_mode === pinn`. La producción seguirá rechazando respuestas incompletas o no verificadas.

Cambios de presentación

El Dashboard identificará el rendimiento como salida del modelo entrenado. Humedad, biomasa, CWSI y economía llevarán etiquetas de simulación o cálculo derivado. La interfaz mostrará intervalo predictivo y advertencia de extrapolación cerca del rendimiento, no en una nota separada.

Cambios de configuración

Crear una sola fuente de forzamiento climático compartida por configuración, API y simulador. Al cambiar escenario o año se actualizarán los valores enviados. El frontend no mostrará variables que no coincidan con el request efectivo.

Módulos que deben ajustarse

- Dashboard: retirar el ensamble GCM fijo y leer intervalos reales.
- What-if: comparar respuestas verificadas sin declarar un ganador prescriptivo.
- Adaptación: fusionar con What-if y marcar efectos no aprendidos.
- MLOps: mostrar metadata del modelo v3.
- Validación: leer artefactos del modelo activo y no sustitutos heredados.
- Comparación de campos: habilitar solo si el alcance espacial está validado.
- Reportes: exportar versión, hash, intervalo y procedencia.

Fase 10 pruebas

Pruebas de datos

- Esquema, tipos, unidades y rangos.
- Unicidad condado-año.
- Ausencia de targets duplicados por SSP.
- Cobertura temporal y espacial mínima.
- Detección de cambios de distribución.
- Hash reproducible del dataset.

Pruebas de entrenamiento

- Separación temporal sin solapamiento.
- Transformaciones ajustadas solo con entrenamiento.
- Reproducibilidad con seed fija.
- Comparación automática contra baselines.
- Validación de metadata y dominio.
- Fallo obligatorio cuando solo está disponible el fallback sintético para una corrida de producción.

Pruebas de inferencia

- Carga del artefacto exacto.
- Igualdad entre predicción offline y API.
- Unidades correctas.
- Intervalos ordenados y finitos.
- Detección de extrapolación.
- Rechazo de features faltantes.
- Pruebas doradas de regresión.

Pruebas de integración

- React envía exactamente los forzantes mostrados.
- Producción no acepta fallback local.
- El badge presenta modelo versión y fuente correctos.
- PDF y XLSX incluyen procedencia.
- La validación usa el modelo activo.
- Rollback restaura v2 sin migraciones destructivas.

Pruebas científicas

- Métricas temporales y espaciales calculadas sobre unidades independientes.
- Comparación de predicciones contra observaciones por año y región.
- Sensibilidad coherente con las features reales del modelo.
- Intervalos evaluados por cobertura.
- Escenarios futuros ejecutados por miembro GCM real.

Fase 11 despliegue progresivo

Etapas de sombra

Ejecutar v2 y v3 para las mismas solicitudes sin mostrar v3 al usuario. Registrar diferencias, tiempos, errores, extrapolaciones y disponibilidad. No guardar información personal ni entradas sensibles en logs.

Etapas de revisión

Revisar una muestra de resultados con perfiles científicos y de ingeniería. Verificar que los cambios se explican por features y no por errores de unidades o transformación.

Etapas canaria

Habilitar v3 para una fracción controlada de tráfico o mediante una bandera interna. Mantener monitoreo de errores, latencia y porcentaje de extrapolaciones.

Promoción

Cambiar el alias del modelo activo cuando se cumplan los criterios técnicos y científicos. Conservar v2 durante una ventana de rollback. La UI y los reportes deberán mostrar inmediatamente la versión activa.

Monitoreo

- Disponibilidad y latencia de inferencia.
- Distribución de variables de entrada.
- Porcentaje de solicitudes fuera de dominio.
- Distribución de predicciones por región y escenario.
- Errores de esquema.
- Deriva cuando se incorporen nuevos rendimientos observados.

Cambios propuestos por archivo

Ruta	Cambio principal
backend/data/nass.py	Preservar FIPS estado condado unidad y trazabilidad
backend/data/nex_gddp.py	Agregar clima por geografía año escenario GCM y variable
backend/data/chirps.py	Generar precipitación histórica por unidad espacial
backend/training/dataset.py	Sustituir expansión SSP por panel histórico canónico
backend/training/config.py	Versionar features esquema splits y rutas
backend/training/train.py	Entrenar pipeline v3 registrar baselines e incertidumbre
backend/training/pinn.py	Mantener solo para compatibilidad o renombrar el modelo experimental
backend/inference.py	Separar adaptador de modelo y simulador determinista
backend/app.py	Exponer contrato neutral y metadata completa

Ruta	Cambio principal
backend/validation.py	Leer artefactos del modelo activo y retirar sustitutos
src/services/api.ts	Validar modelo verificado en vez de exigir PINN
src/components/MainDashboard.tsx	Mostrar intervalo procedencia y extrapolación
src/components/SimulationConfig.tsx	Sincronizar escenario año y forzantes enviados
src/components/MLOpsDashboard.tsx	Mostrar dataset hash alcance y métricas prospectivas
src/components/ValidationReport.tsx	Presentar validación temporal espacial y cobertura reales
tests	Agregar pruebas de datos modelo API frontend y rollback

Plan de trabajo indicativo

La duración depende del acceso a APIs, cobertura climática y recursos de cómputo. El siguiente orden es más importante que las fechas.

Bloque	Trabajo	Duración indicativa	Dependencia
1	Línea base contratos y pruebas	1 semana	Ninguna
2	Ruta A regional y API neutral	1 a 2 semanas	Bloque 1
3	Reextracción NASS y clima espacial	2 a 4 semanas	Acceso a fuentes
4	Panel canónico y QA	1 a 2 semanas	Bloque 3
5	Modelos validación e incertidumbre	2 a 3 semanas	Bloque 4
6	Integración backend y frontend	1 a 2 semanas	Bloque 5
7	Sombra revisión y promoción	1 a 2 semanas	Bloque 6

Con trabajo secuencial, la ruta B requiere aproximadamente ocho a doce semanas. La ruta A puede quedar integrada antes, siempre que se mantenga su clasificación regional exploratoria.

Roles requeridos

Rol	Responsabilidad
Ingeniería de datos	Extracción geográfica panel calidad y manifiestos
Ciencia de datos	Features modelos validación incertidumbre y errores
Revisión científica	Alcance agronómico diseño de variables y afirmaciones
Backend	Adaptadores contratos registro despliegue y observabilidad
Frontend	Procedencia incertidumbre configuración y módulos
Calidad	Tests reproducibilidad seguridad y criterios de promoción

Riesgos y mitigaciones

Riesgo	Impacto	Mitigación
Clima histórico sin cobertura consistente	El panel no puede entrenarse de forma homogénea	Definir una fuente observacional alternativa y documentar el cambio
Pocos años independientes	Alta varianza y extrapolación	Usar panel espacial modelos simples regularización e intervalos

Riesgo	Impacto	Mitigación
Fuga por filas repetidas	Métricas infladas	Dividir por año y geografía antes de cualquier transformación
SSP correlacionado con CO2 y riesgo	Efectos no identificables	No entrenar con etiquetas SSP replicadas
Diferencias de unidades	Predicciones físicamente absurdas	Esquema tipado validaciones y tests dorados
Intervalos demasiado estrechos	Falsa confianza	Evaluar cobertura prospectiva y mostrar anchura
Deriva futura	Degradación silenciosa	OOD monitoreo y reentrenamiento versionado
Frontend mezcla procedencias	El usuario interpreta simulación como ML	Etiquetas por componente y contrato obligatorio
Promoción de un modelo peor	Regresión científica	Baselines gates etapa sombra y rollback atómico

Criterios de terminado

El trabajo estará terminado cuando se cumplan todos los puntos siguientes:

1. Existe un panel histórico versionado sin replicación de targets por SSP.
2. La unidad espacial y temporal es explícita y trazable.
3. El modelo activo supera el baseline acordado en validación prospectiva o permanece marcado como experimental.
4. La evaluación espacial se reporta antes de habilitar comparaciones territoriales.
5. Cada predicción incluye intervalo, versión, hash, alcance y bandera de extrapolación.
6. FastAPI carga el artefacto versionado y reproduce las predicciones offline.
7. React acepta un modelo ML verificado sin llamarlo PINN.
8. El frontend distingue salida aprendida, simulación determinista y cálculo derivado.
9. Producción no utiliza fallback sintético o local de manera silenciosa.
10. Los reportes y la pantalla de validación leen métricas del modelo activo.
11. Las pruebas de datos entrenamiento inferencia integración y rollback pasan.
12. El modelo anterior puede restaurarse mediante un cambio de alias documentado.

Primera iteración recomendada

La primera iteración debe completar Fase 0 y Ruta A sin reemplazar todavía el modelo de producción. Su objetivo será construir la interfaz neutral de inferencia, corregir la validación temporal, eliminar la replicación SSP y comparar Ridge Random Forest HistGradientBoosting y una MLP pequeña sobre las 36 unidades anuales.

En paralelo debe iniciarse la Ruta B, comenzando por preservar FIPS en NASS y producir clima histórico por condado-año. El modelo v3 solo se promoverá cuando esa ruta demuestre habilidad prospectiva y, para funciones territoriales, validación espacial independiente.

Referencias internas

- [data/README.md](#)
- [backend/training/dataset.py](#)
- [backend/training/config.py](#)

- backend/training/train.py
- backend/training/pinn.py
- backend/inference.py
- backend/app.py
- docs/q1_artifacts/temporal/temporal_validation_1990_2017_to_2018_2025.json
- docs/q1_artifacts/same_split_baseline_comparison.csv
- docs/auditoria_modelo_y_modulos_frontend_2026-09-25.md